

DÉRIVÉES & GRADIENTS

Jérémie Cabessa
Laboratoire DAVID, UVSQ

DÉRIVÉE

- Soit $f : \mathbb{R} \longrightarrow \mathbb{R}$ une fonction. On dit que f est *différentiable* au point $x_0 \in \mathbb{R}$ si la limite suivante existe:

$$\frac{df}{dx}(x_0) := \lim_{h \rightarrow 0} \frac{f(x_0 + h) - f(x_0)}{h}$$

DÉRIVÉE

- Soit $f : \mathbb{R} \longrightarrow \mathbb{R}$ une fonction. On dit que f est *différentiable* au point $x_0 \in \mathbb{R}$ si la limite suivante existe:

$$\frac{df}{dx}(x_0) := \lim_{h \rightarrow 0} \frac{f(x_0 + h) - f(x_0)}{h}$$

- Supposons f différentiable en tous points. Alors la limite

$$f'(x_0) := \frac{df}{dx}(x_0)$$

est la *dérivée* de f en x_0 .

RÈGLES DE DÉRIVATION

- *Composition (chain rule)*: si f est différentiable en x et g est différentiable en $f(x)$, alors $g \circ f$ est différentiable en x et

$$(g \circ f)'(x) = g'(f(x)) \cdot f'(x)$$

- En notation de Leibniz, si $u = f(x)$ et $y = g(u)$, alors

$$\frac{dy}{dx} = \frac{dy}{du} \cdot \frac{du}{dx}$$

- Plus généralement, pour une composition de n fonctions:

$$(f_n \circ \cdots \circ f_1)'(x) = f_n'(u_{n-1}) \cdot \cdots \cdot f_2'(u_1) \cdot f_1'(x)$$

où $u_i := (f_i \circ \cdots \circ f_1)(x)$.

- Cette règle est **fondamentale** en machine learning: elle est au coeur de l'algorithme de *rétropropagation* (**backpropagation**).

RÈGLES DE DÉRIVATION

Exemples:

► $f(x) = x^2 e^x$ (produit):

$$f'(x) = 2x e^x + x^2 e^x = (x^2 + 2x) e^x$$

► $f(x) = \frac{x}{1+x^2}$ (quotient):

$$f'(x) = \frac{1 \cdot (1+x^2) - x \cdot 2x}{(1+x^2)^2} = \frac{1-x^2}{(1+x^2)^2}$$

► $f(x) = e^{-x^2}$ (composition, avec $u = -x^2$):

$$f'(x) = e^{-x^2} \cdot (-2x) = -2x e^{-x^2}$$

RÈGLES DE DÉRIVATION

Exemples:

► $f(x) = x^2 e^x$ (produit):

$$f'(x) = 2x e^x + x^2 e^x = (x^2 + 2x) e^x$$

► $f(x) = \frac{x}{1+x^2}$ (quotient):

$$f'(x) = \frac{1 \cdot (1+x^2) - x \cdot 2x}{(1+x^2)^2} = \frac{1-x^2}{(1+x^2)^2}$$

► $f(x) = e^{-x^2}$ (composition, avec $u = -x^2$):

$$f'(x) = e^{-x^2} \cdot (-2x) = -2x e^{-x^2}$$

RÈGLES DE DÉRIVATION

Exemples:

- $f(x) = x^2 e^x$ (produit):

$$f'(x) = 2x e^x + x^2 e^x = (x^2 + 2x) e^x$$

- $f(x) = \frac{x}{1+x^2}$ (quotient):

$$f'(x) = \frac{1 \cdot (1+x^2) - x \cdot 2x}{(1+x^2)^2} = \frac{1-x^2}{(1+x^2)^2}$$

- $f(x) = e^{-x^2}$ (composition, avec $u = -x^2$):

$$f'(x) = e^{-x^2} \cdot (-2x) = -2x e^{-x^2}$$

RÈGLES DE DÉRIVATION: EXERCICES

Ces règles se démontrent **directement** à partir de la définition de la dérivée comme limite.

- ▶ **Exercice 1.** Montrer que $(f + g)' = f' + g'$ et $(\lambda f)' = \lambda f'$.
- ▶ **Exercice 2.** Montrer que $(f \cdot g)' = f' \cdot g + f \cdot g'$.
Indication: ajouter et soustraire le terme $f(x)g(x+h)$.
- ▶ **Exercice 3.** Montrer que $\left(\frac{1}{g}\right)' = -\frac{g'}{g^2}$, puis en déduire la règle du quotient à l'aide de l'exercice 2.

RÈGLES DE DÉRIVATION: EXERCICES

Ces règles se démontrent **directement** à partir de la définition de la dérivée comme limite.

- ▶ **Exercice 1.** Montrer que $(f + g)' = f' + g'$ et $(\lambda f)' = \lambda f'$.
- ▶ **Exercice 2.** Montrer que $(f \cdot g)' = f' \cdot g + f \cdot g'$.
Indication: ajouter et soustraire le terme $f(x)g(x+h)$.
- ▶ **Exercice 3.** Montrer que $\left(\frac{1}{g}\right)' = -\frac{g'}{g^2}$, puis en déduire la règle du quotient à l'aide de l'exercice 2.

RÈGLES DE DÉRIVATION: EXERCICES

Ces règles se démontrent **directement** à partir de la définition de la dérivée comme limite.

- ▶ **Exercice 1.** Montrer que $(f + g)' = f' + g'$ et $(\lambda f)' = \lambda f'$.
- ▶ **Exercice 2.** Montrer que $(f \cdot g)' = f' \cdot g + f \cdot g'$.
Indication: ajouter et soustraire le terme $f(x)g(x+h)$.
- ▶ **Exercice 3.** Montrer que $\left(\frac{1}{g}\right)' = -\frac{g'}{g^2}$, puis en déduire la règle du quotient à l'aide de l'exercice 2.

RÈGLES DE DÉRIVATION: CORRIGÉS

Exercice 1 (somme):

$$\begin{aligned}(f + g)'(x) &= \lim_{h \rightarrow 0} \frac{(f + g)(x + h) - (f + g)(x)}{h} \\&= \lim_{h \rightarrow 0} \frac{f(x + h) + g(x + h) - f(x) - g(x)}{h} \\&= \lim_{h \rightarrow 0} \left(\frac{f(x + h) - f(x)}{h} + \frac{g(x + h) - g(x)}{h} \right) \\&= \lim_{h \rightarrow 0} \frac{f(x + h) - f(x)}{h} + \lim_{h \rightarrow 0} \frac{g(x + h) - g(x)}{h} \\&= f'(x) + g'(x)\end{aligned}$$

(l'avant-dernière égalité utilise: la limite d'une somme est la somme des limites)



RÈGLES DE DÉRIVATION: CORRIGÉS

Exercice 1 (somme):

$$\begin{aligned}(f + g)'(x) &= \lim_{h \rightarrow 0} \frac{(f + g)(x + h) - (f + g)(x)}{h} \\&= \lim_{h \rightarrow 0} \frac{f(x + h) + g(x + h) - f(x) - g(x)}{h} \\&= \lim_{h \rightarrow 0} \left(\frac{f(x + h) - f(x)}{h} + \frac{g(x + h) - g(x)}{h} \right) \\&= \lim_{h \rightarrow 0} \frac{f(x + h) - f(x)}{h} + \lim_{h \rightarrow 0} \frac{g(x + h) - g(x)}{h} \\&= f'(x) + g'(x)\end{aligned}$$

(l'avant-dernière égalité utilise: la limite d'une somme est la somme des limites)



RÈGLES DE DÉRIVATION: CORRIGÉS

Exercice 1 (multiple scalaire):

$$\begin{aligned}(\lambda f)'(x) &= \lim_{h \rightarrow 0} \frac{(\lambda f)(x+h) - (\lambda f)(x)}{h} \\&= \lim_{h \rightarrow 0} \frac{\lambda f(x+h) - \lambda f(x)}{h} \\&= \lim_{h \rightarrow 0} \lambda \cdot \frac{f(x+h) - f(x)}{h} \\&= \lambda \cdot \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\&= \lambda f'(x)\end{aligned}$$

(l'avant-dernière égalité utilise: une constante sort de la limite)



RÈGLES DE DÉRIVATION: CORRIGÉS

Exercice 1 (multiple scalaire):

$$\begin{aligned}(\lambda f)'(x) &= \lim_{h \rightarrow 0} \frac{(\lambda f)(x+h) - (\lambda f)(x)}{h} \\&= \lim_{h \rightarrow 0} \frac{\lambda f(x+h) - \lambda f(x)}{h} \\&= \lim_{h \rightarrow 0} \lambda \cdot \frac{f(x+h) - f(x)}{h} \\&= \lambda \cdot \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\&= \lambda f'(x)\end{aligned}$$

(l'avant-dernière égalité utilise: une constante sort de la limite)



RÈGLES DE DÉRIVATION: CORRIGÉS

Exercice 2 (produit):

$$\begin{aligned}
& (f \cdot g)'(x) \\
&= \lim_{h \rightarrow 0} \frac{(f \cdot g)(x+h) - (f \cdot g)(x)}{h} \\
&= \lim_{h \rightarrow 0} \frac{f(x+h)g(x+h) - f(x)g(x+h) + f(x)g(x+h) - f(x)g(x)}{h} \\
&= \lim_{h \rightarrow 0} \frac{(f(x+h) - f(x))g(x+h) + f(x)(g(x+h) - g(x))}{h} \\
&= \lim_{h \rightarrow 0} \left(\frac{f(x+h) - f(x)}{h} \cdot g(x+h) + f(x) \cdot \frac{g(x+h) - g(x)}{h} \right) \\
&= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \cdot \lim_{h \rightarrow 0} g(x+h) + f(x) \cdot \lim_{h \rightarrow 0} \frac{g(x+h) - g(x)}{h} \\
&= f'(x)g(x) + f(x)g'(x)
\end{aligned}$$

(la deuxième égalité ajoute et soustrait $f(x)g(x+h)$; la dernière utilise

$\lim_{h \rightarrow 0} g(x+h) = g(x)$, car g différentiable $\Rightarrow g$ continue)

RÈGLES DE DÉRIVATION: CORRIGÉS

Exercice 2 (produit):

$$\begin{aligned}
& (f \cdot g)'(x) \\
&= \lim_{h \rightarrow 0} \frac{(f \cdot g)(x+h) - (f \cdot g)(x)}{h} \\
&= \lim_{h \rightarrow 0} \frac{f(x+h)g(x+h) - f(x)g(x+h) + f(x)g(x+h) - f(x)g(x)}{h} \\
&= \lim_{h \rightarrow 0} \frac{(f(x+h) - f(x))g(x+h) + f(x)(g(x+h) - g(x))}{h} \\
&= \lim_{h \rightarrow 0} \left(\frac{f(x+h) - f(x)}{h} \cdot g(x+h) + f(x) \cdot \frac{g(x+h) - g(x)}{h} \right) \\
&= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \cdot \lim_{h \rightarrow 0} g(x+h) + f(x) \cdot \lim_{h \rightarrow 0} \frac{g(x+h) - g(x)}{h} \\
&= f'(x)g(x) + f(x)g'(x)
\end{aligned}$$

(la deuxième égalité ajoute et soustrait $f(x)g(x+h)$; la dernière utilise

$\lim_{h \rightarrow 0} g(x+h) = g(x)$, car g différentiable $\Rightarrow g$ continue)

RÈGLES DE DÉRIVATION: CORRIGÉS

Exercice 3 (inverse):

$$\begin{aligned}
\left(\frac{1}{g}\right)'(x) &= \lim_{h \rightarrow 0} \frac{1}{h} \left(\frac{1}{g(x+h)} - \frac{1}{g(x)} \right) \\
&= \lim_{h \rightarrow 0} \frac{1}{h} \cdot \frac{g(x) - g(x+h)}{g(x+h)g(x)} \\
&= \lim_{h \rightarrow 0} \left(-\frac{g(x+h) - g(x)}{h} \cdot \frac{1}{g(x+h)g(x)} \right) \\
&= -\lim_{h \rightarrow 0} \frac{g(x+h) - g(x)}{h} \cdot \lim_{h \rightarrow 0} \frac{1}{g(x+h)g(x)} \\
&= -g'(x) \cdot \frac{1}{g(x)^2} = -\frac{g'(x)}{g(x)^2}
\end{aligned}$$

(la dernière égalité utilise à nouveau la continuité de g)

RÈGLES DE DÉRIVATION: CORRIGÉS

Exercice 3 (inverse):

$$\begin{aligned}
\left(\frac{1}{g}\right)'(x) &= \lim_{h \rightarrow 0} \frac{1}{h} \left(\frac{1}{g(x+h)} - \frac{1}{g(x)} \right) \\
&= \lim_{h \rightarrow 0} \frac{1}{h} \cdot \frac{g(x) - g(x+h)}{g(x+h)g(x)} \\
&= \lim_{h \rightarrow 0} \left(-\frac{g(x+h) - g(x)}{h} \cdot \frac{1}{g(x+h)g(x)} \right) \\
&= -\lim_{h \rightarrow 0} \frac{g(x+h) - g(x)}{h} \cdot \lim_{h \rightarrow 0} \frac{1}{g(x+h)g(x)} \\
&= -g'(x) \cdot \frac{1}{g(x)^2} = -\frac{g'(x)}{g(x)^2}
\end{aligned}$$

(la dernière égalité utilise à nouveau la continuité de g)

RÈGLES DE DÉRIVATION: CORRIGÉS

Exercice 3 (quotient): il n'est pas nécessaire de repasser par la limite: on écrit $\frac{f}{g} = f \cdot \frac{1}{g}$ et on applique les exercices 2 puis 3.

$$\begin{aligned}\left(\frac{f}{g}\right)'(x) &= \left(f \cdot \frac{1}{g}\right)'(x) \\ &= f'(x) \cdot \frac{1}{g(x)} + f(x) \cdot \left(\frac{1}{g}\right)'(x) \\ &= f'(x) \cdot \frac{1}{g(x)} + f(x) \cdot \left(-\frac{g'(x)}{g^2(x)}\right) \\ &= \frac{f'(x)g(x) - f(x)g'(x)}{g^2(x)}\end{aligned}$$



RÈGLES DE DÉRIVATION: CORRIGÉS

Exercice 3 (quotient): il n'est pas nécessaire de repasser par la limite: on écrit $\frac{f}{g} = f \cdot \frac{1}{g}$ et on applique les exercices 2 puis 3.

$$\begin{aligned}
 \left(\frac{f}{g}\right)'(x) &= \left(f \cdot \frac{1}{g}\right)'(x) \\
 &= f'(x) \cdot \frac{1}{g(x)} + f(x) \cdot \left(\frac{1}{g}\right)'(x) \\
 &= f'(x) \cdot \frac{1}{g(x)} + f(x) \cdot \left(-\frac{g'(x)}{g^2(x)}\right) \\
 &= \frac{f'(x)g(x) - f(x)g'(x)}{g^2(x)}
 \end{aligned}$$



RÈGLES DE DÉRIVATION: CORRIGÉS

Exercice 3 (quotient): il n'est pas nécessaire de repasser par la limite: on écrit $\frac{f}{g} = f \cdot \frac{1}{g}$ et on applique les exercices 2 puis 3.

$$\begin{aligned}
 \left(\frac{f}{g}\right)'(x) &= \left(f \cdot \frac{1}{g}\right)'(x) \\
 &= f'(x) \cdot \frac{1}{g(x)} + f(x) \cdot \left(\frac{1}{g}\right)'(x) \\
 &= f'(x) \cdot \frac{1}{g(x)} + f(x) \cdot \left(-\frac{g'(x)}{g^2(x)}\right) \\
 &= \frac{f'(x)g(x) - f(x)g'(x)}{g^2(x)}
 \end{aligned}$$



RÈGLES DE DÉRIVATION: COMPOSITION

Idée de preuve (chain rule): lorsque $f(x+h) \neq f(x)$, on peut écrire

$$\frac{g(f(x+h)) - g(f(x))}{h} = \frac{g(f(x+h)) - g(f(x))}{f(x+h) - f(x)} \cdot \frac{f(x+h) - f(x)}{h}.$$

Le second facteur tend vers $f'(x)$, et le premier vers $g'(f(x))$ car $f(x+h) \rightarrow f(x)$. D'où $(g \circ f)'(x) = g'(f(x)) \cdot f'(x)$.

Attention: cet argument suppose $f(x+h) \neq f(x)$ pour h petit, ce qui n'est pas toujours vrai. Une preuve rigoureuse demande un peu plus de soin (admis ici).

RÈGLES DE DÉRIVATION: COMPOSITION

Idée de preuve (chain rule): lorsque $f(x+h) \neq f(x)$, on peut écrire

$$\frac{g(f(x+h)) - g(f(x))}{h} = \frac{g(f(x+h)) - g(f(x))}{f(x+h) - f(x)} \cdot \frac{f(x+h) - f(x)}{h}.$$

Le second facteur tend vers $f'(x)$, et le premier vers $g'(f(x))$ car $f(x+h) \rightarrow f(x)$. D'où $(g \circ f)'(x) = g'(f(x)) \cdot f'(x)$.

Attention: cet argument suppose $f(x+h) \neq f(x)$ pour h petit, ce qui n'est pas toujours vrai. Une preuve rigoureuse demande un peu plus de soin (admis ici).

RÈGLES DE DÉRIVATION: COMPOSITION

Idée de preuve (chain rule): lorsque $f(x+h) \neq f(x)$, on peut écrire

$$\frac{g(f(x+h)) - g(f(x))}{h} = \frac{g(f(x+h)) - g(f(x))}{f(x+h) - f(x)} \cdot \frac{f(x+h) - f(x)}{h}.$$

Le second facteur tend vers $f'(x)$, et le premier vers $g'(f(x))$ car $f(x+h) \rightarrow f(x)$. D'où $(g \circ f)'(x) = g'(f(x)) \cdot f'(x)$.

Attention: cet argument suppose $f(x+h) \neq f(x)$ pour h petit, ce qui n'est pas toujours vrai. Une preuve rigoureuse demande un peu plus de soin (admis ici).

RÈGLES DE DÉRIVATION: COMPOSITION

Idée de preuve (chain rule): lorsque $f(x+h) \neq f(x)$, on peut écrire

$$\frac{g(f(x+h)) - g(f(x))}{h} = \frac{g(f(x+h)) - g(f(x))}{f(x+h) - f(x)} \cdot \frac{f(x+h) - f(x)}{h}.$$

Le second facteur tend vers $f'(x)$, et le premier vers $g'(f(x))$ car $f(x+h) \rightarrow f(x)$. D'où $(g \circ f)'(x) = g'(f(x)) \cdot f'(x)$.

Attention: cet argument suppose $f(x+h) \neq f(x)$ pour h petit, ce qui n'est pas toujours vrai. Une preuve rigoureuse demande un peu plus de soin (admis ici).

RÈGLES DE DÉRIVATION: COMPOSITION

Idée de preuve (chain rule): lorsque $f(x+h) \neq f(x)$, on peut écrire

$$\frac{g(f(x+h)) - g(f(x))}{h} = \frac{g(f(x+h)) - g(f(x))}{f(x+h) - f(x)} \cdot \frac{f(x+h) - f(x)}{h}.$$

Le second facteur tend vers $f'(x)$, et le premier vers $g'(f(x))$ car $f(x+h) \rightarrow f(x)$. D'où $(g \circ f)'(x) = g'(f(x)) \cdot f'(x)$.

Attention: cet argument suppose $f(x+h) \neq f(x)$ pour h petit, ce qui n'est pas toujours vrai. Une preuve rigoureuse demande un peu plus de soin (admis ici).

RÈGLES DE DÉRIVATION: REMARQUE

- ▶ Les règles précédentes se démontrent donc **entièrement** à partir de la définition de la dérivée.
- ▶ En revanche, les dérivées des fonctions e^x , $\ln(x)$, $\sin(x)$, ... ne s'obtiennent pas aussi directement: elles dépendent de la *définition précise* que l'on donne à ces fonctions.
- ▶ Par exemple, pour $f(x) = e^x$,

$$\frac{e^{x+h} - e^x}{h} = e^x \cdot \frac{e^h - 1}{h} \xrightarrow{h \rightarrow 0} e^x \cdot 1,$$

mais la limite $\frac{e^h - 1}{h} \rightarrow 1$ est précisément ce qui *caractérise* le nombre e .

- ▶ Ces dérivées seront donc **admises**.

RÈGLES DE DÉRIVATION: REMARQUE

- ▶ Les règles précédentes se démontrent donc **entièrement** à partir de la définition de la dérivée.
- ▶ En revanche, les dérivées des fonctions e^x , $\ln(x)$, $\sin(x)$, ... ne s'obtiennent pas aussi directement: elles dépendent de la *définition précise* que l'on donne à ces fonctions.
- ▶ Par exemple, pour $f(x) = e^x$,

$$\frac{e^{x+h} - e^x}{h} = e^x \cdot \frac{e^h - 1}{h} \xrightarrow{h \rightarrow 0} e^x \cdot 1,$$

mais la limite $\frac{e^h - 1}{h} \rightarrow 1$ est précisément ce qui *caractérise* le nombre e .

- ▶ Ces dérivées seront donc **admises**.

RÈGLES DE DÉRIVATION: REMARQUE

- ▶ Les règles précédentes se démontrent donc **entièrement** à partir de la définition de la dérivée.
- ▶ En revanche, les dérivées des fonctions e^x , $\ln(x)$, $\sin(x)$, ... ne s'obtiennent pas aussi directement: elles dépendent de la *définition précise* que l'on donne à ces fonctions.
- ▶ Par exemple, pour $f(x) = e^x$,

$$\frac{e^{x+h} - e^x}{h} = e^x \cdot \frac{e^h - 1}{h} \xrightarrow{h \rightarrow 0} e^x \cdot 1,$$

mais la limite $\frac{e^h - 1}{h} \rightarrow 1$ est précisément ce qui *caractérise* le nombre e .

- ▶ Ces dérivées seront donc **admisses**.

RÈGLES DE DÉRIVATION: REMARQUE

- ▶ Les règles précédentes se démontrent donc **entièrement** à partir de la définition de la dérivée.
- ▶ En revanche, les dérivées des fonctions e^x , $\ln(x)$, $\sin(x)$, ... ne s'obtiennent pas aussi directement: elles dépendent de la *définition précise* que l'on donne à ces fonctions.
- ▶ Par exemple, pour $f(x) = e^x$,

$$\frac{e^{x+h} - e^x}{h} = e^x \cdot \frac{e^h - 1}{h} \xrightarrow{h \rightarrow 0} e^x \cdot 1,$$

mais la limite $\frac{e^h - 1}{h} \rightarrow 1$ est précisément ce qui *caractérise* le nombre e .

- ▶ Ces dérivées seront donc **admisses**.

DÉRIVÉES DES FONCTIONS USUELLES

$f(x)$	$f'(x)$	domaine
c	0	$x \in \mathbb{R}$
x	1	$x \in \mathbb{R}$
$x^n, \quad n \in \mathbb{N}$	$n x^{n-1}$	$x \in \mathbb{R}$
$x^\alpha, \quad \alpha \in \mathbb{R}$	$\alpha x^{\alpha-1}$	$x > 0$
$\frac{1}{x}$	$-\frac{1}{x^2}$	$x \neq 0$
$\sqrt{x}$	$\frac{1}{2\sqrt{x}}$	$x > 0$
$ x $	$\frac{x}{ x }$	$x \neq 0$

DÉRIVÉES DES FONCTIONS USUELLES

$f(x)$	$f'(x)$	domaine
e^x	e^x	$x \in \mathbb{R}$
$a^x, \quad a > 0$	$a^x \ln(a)$	$x \in \mathbb{R}$
$\ln(x)$	$\frac{1}{x}$	$x > 0$
$\log_a(x), \quad a > 0, a \neq 1$	$\frac{1}{x \ln(a)}$	$x > 0$
$\sin(x)$	$\cos(x)$	$x \in \mathbb{R}$
$\cos(x)$	$-\sin(x)$	$x \in \mathbb{R}$
$\tan(x)$	$1 + \tan^2(x) = \frac{1}{\cos^2(x)}$	$x \neq \frac{\pi}{2} + k\pi$

DÉRIVÉES DES FONCTIONS USUELLES

- Combinées à la **chain rule**, ces dérivées donnent les formes suivantes, où u est une fonction différentiable:

$f(x)$	$f'(x)$
$u(x)^n$	$n u(x)^{n-1} u'(x)$
$e^{u(x)}$	$u'(x) e^{u(x)}$
$\ln(u(x))$	$\frac{u'(x)}{u(x)}$
$\sqrt{u(x)}$	$\frac{u'(x)}{2\sqrt{u(x)}}$

DÉRIVÉES DES FONCTIONS D'ACTIVATION

► *Sigmoïde*: $\sigma(x) = \frac{1}{1 + e^{-x}}$

$$\sigma'(x) = \sigma(x)(1 - \sigma(x))$$

► *Tangente hyperbolique*: $\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$

$$\tanh'(x) = 1 - \tanh^2(x)$$

► *ReLU*: $\text{ReLU}(x) = \max(0, x)$

$$\text{ReLU}'(x) = \begin{cases} 0 & \text{si } x < 0 \\ 1 & \text{si } x > 0 \end{cases} \quad (\text{non différentiable en } 0)$$

DÉRIVÉES DES FONCTIONS D'ACTIVATION

► *Sigmoïde*: $\sigma(x) = \frac{1}{1 + e^{-x}}$

$$\sigma'(x) = \sigma(x)(1 - \sigma(x))$$

► *Tangente hyperbolique*: $\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$

$$\tanh'(x) = 1 - \tanh^2(x)$$

► *ReLU*: $\text{ReLU}(x) = \max(0, x)$

$$\text{ReLU}'(x) = \begin{cases} 0 & \text{si } x < 0 \\ 1 & \text{si } x > 0 \end{cases} \quad (\text{non différentiable en } 0)$$

DÉRIVÉES DES FONCTIONS D'ACTIVATION

► *Sigmoïde*: $\sigma(x) = \frac{1}{1 + e^{-x}}$

$$\sigma'(x) = \sigma(x)(1 - \sigma(x))$$

► *Tangente hyperbolique*: $\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$

$$\tanh'(x) = 1 - \tanh^2(x)$$

► *ReLU*: $\text{ReLU}(x) = \max(0, x)$

$$\text{ReLU}'(x) = \begin{cases} 0 & \text{si } x < 0 \\ 1 & \text{si } x > 0 \end{cases} \quad (\text{non différentiable en } 0)$$

DÉRIVÉES DES FONCTIONS D'ACTIVATION

Preuve (dérivée de la sigmoïde): on écrit $\sigma(x) = (1 + e^{-x})^{-1}$. Par la chain rule,

$$\sigma'(x) = -(1 + e^{-x})^{-2} \cdot (-e^{-x}) = \frac{e^{-x}}{(1 + e^{-x})^2}.$$

Or,

$$\frac{e^{-x}}{(1 + e^{-x})^2} = \frac{1}{1 + e^{-x}} \cdot \frac{e^{-x}}{1 + e^{-x}} = \frac{1}{1 + e^{-x}} \cdot \left(1 - \frac{1}{1 + e^{-x}}\right).$$

Ainsi,

$$\sigma'(x) = \sigma(x)(1 - \sigma(x)).$$



DÉRIVÉES DES FONCTIONS D'ACTIVATION

Preuve (dérivée de la sigmoïde): on écrit $\sigma(x) = (1 + e^{-x})^{-1}$. Par la chain rule,

$$\sigma'(x) = -(1 + e^{-x})^{-2} \cdot (-e^{-x}) = \frac{e^{-x}}{(1 + e^{-x})^2}.$$

Or,

$$\frac{e^{-x}}{(1 + e^{-x})^2} = \frac{1}{1 + e^{-x}} \cdot \frac{e^{-x}}{1 + e^{-x}} = \frac{1}{1 + e^{-x}} \cdot \left(1 - \frac{1}{1 + e^{-x}}\right).$$

Ainsi,

$$\sigma'(x) = \sigma(x)(1 - \sigma(x)).$$



DÉRIVÉES DES FONCTIONS D'ACTIVATION

Preuve (dérivée de la sigmoïde): on écrit $\sigma(x) = (1 + e^{-x})^{-1}$. Par la chain rule,

$$\sigma'(x) = -(1 + e^{-x})^{-2} \cdot (-e^{-x}) = \frac{e^{-x}}{(1 + e^{-x})^2}.$$

Or,

$$\frac{e^{-x}}{(1 + e^{-x})^2} = \frac{1}{1 + e^{-x}} \cdot \frac{e^{-x}}{1 + e^{-x}} = \frac{1}{1 + e^{-x}} \cdot \left(1 - \frac{1}{1 + e^{-x}}\right).$$

Ainsi,

$$\sigma'(x) = \sigma(x)(1 - \sigma(x)).$$



DÉRIVÉES DES FONCTIONS D'ACTIVATION

Preuve (dérivée de la sigmoïde): on écrit $\sigma(x) = (1 + e^{-x})^{-1}$. Par la chain rule,

$$\sigma'(x) = -(1 + e^{-x})^{-2} \cdot (-e^{-x}) = \frac{e^{-x}}{(1 + e^{-x})^2}.$$

Or,

$$\frac{e^{-x}}{(1 + e^{-x})^2} = \frac{1}{1 + e^{-x}} \cdot \frac{e^{-x}}{1 + e^{-x}} = \frac{1}{1 + e^{-x}} \cdot \left(1 - \frac{1}{1 + e^{-x}}\right).$$

Ainsi,

$$\sigma'(x) = \sigma(x)(1 - \sigma(x)).$$



DÉRIVÉES DES FONCTIONS D'ACTIVATION

Preuve (dérivée de la sigmoïde): on écrit $\sigma(x) = (1 + e^{-x})^{-1}$. Par la chain rule,

$$\sigma'(x) = -(1 + e^{-x})^{-2} \cdot (-e^{-x}) = \frac{e^{-x}}{(1 + e^{-x})^2}.$$

Or,

$$\frac{e^{-x}}{(1 + e^{-x})^2} = \frac{1}{1 + e^{-x}} \cdot \frac{e^{-x}}{1 + e^{-x}} = \frac{1}{1 + e^{-x}} \cdot \left(1 - \frac{1}{1 + e^{-x}}\right).$$

Ainsi,

$$\sigma'(x) = \sigma(x)(1 - \sigma(x)).$$



DÉRIVÉES: EXERCICES

Calculer la dérivée des fonctions suivantes:

(A) $f(x) = 3x^4 - 5x^2 + 7x - 2$

(B) $f(x) = (2x + 1)(x^2 - 3)$

(C) $f(x) = \frac{x^2 + 1}{x - 2}$

(D) $f(x) = \sqrt{3x^2 + 1}$

(E) $f(x) = e^{-2x+1}$

(F) $f(x) = \ln(1 + x^2)$

DÉRIVÉES: EXERCICES

Calculer la dérivée des fonctions suivantes (les dernières apparaissent souvent en machine learning):

(G) $f(x) = x e^{-x^2}$

(H) $f(x) = \ln(1 + e^x)$ (*softplus*)

(I) $f(x) = \frac{1}{1 + e^{-\alpha x}}$ ($\alpha > 0$ fixé)

(J) $L(w) = (y - wx)^2$, dérivée par rapport à w (*err. quadr.*)

(K) $L(w) = -\ln(\sigma(wx))$, dérivée par rapport à w (*log-loss*)

DÉRIVÉES: CORRIGÉS

$$(A) \quad f'(x) = 12x^3 - 10x + 7$$

$$(B) \quad f'(x) = 2(x^2 - 3) + (2x + 1) \cdot 2x = 6x^2 + 2x - 6$$

$$(C) \quad f'(x) = \frac{2x(x - 2) - (x^2 + 1)}{(x - 2)^2} = \frac{x^2 - 4x - 1}{(x - 2)^2}$$

$$(D) \quad f'(x) = \frac{6x}{2\sqrt{3x^2 + 1}} = \frac{3x}{\sqrt{3x^2 + 1}}$$

$$(E) \quad f'(x) = -2e^{-2x+1}$$

$$(F) \quad f'(x) = \frac{2x}{1 + x^2}$$

DÉRIVÉES: CORRIGÉS

$$(G) \quad f'(x) = e^{-x^2} + x \cdot (-2x) e^{-x^2} = (1 - 2x^2) e^{-x^2}$$

$$(H) \quad f'(x) = \frac{e^x}{1 + e^x} = \frac{1}{1 + e^{-x}} = \sigma(x)$$

la dérivée du *softplus* est exactement la *sigmoïde*!

$$(I) \quad f(x) = \sigma(\alpha x), \quad \text{donc} \quad f'(x) = \alpha \sigma(\alpha x) (1 - \sigma(\alpha x))$$

$$(J) \quad \frac{dL}{dw} = 2(y - wx) \cdot (-x) = -2x(y - wx)$$

$$(K) \quad \frac{dL}{dw} = -\frac{\sigma'(wx)}{\sigma(wx)} \cdot x = -x(1 - \sigma(wx))$$

DÉRIVÉE ET EXTREMA

- Les **zéros de la dérivée** sont les candidats naturels pour les **extrema** (minima et maxima) d'une fonction.

THEOREM (FERMAT)

Soit $f :]a, b[\rightarrow \mathbb{R}$ une fonction différentiable. Si f admet un extremum local (minimum ou maximum) en un point $x_0 \in]a, b[$, alors

$$f'(x_0) = 0.$$

DÉRIVÉE ET EXTREMA

- Les **zéros de la dérivée** sont les candidats naturels pour les **extrema** (minima et maxima) d'une fonction.

THEOREM (FERMAT)

Soit $f :]a, b[\rightarrow \mathbb{R}$ une fonction différentiable. Si f admet un extremum local (minimum ou maximum) en un point $x_0 \in]a, b[$, alors

$$f'(x_0) = 0.$$

DÉRIVÉE ET EXTREMA


- Les **zéros de la dérivée** sont les candidats naturels pour les **extrema** (minima et maxima) d'une fonction.

THEOREM (FERMAT)

Soit $f :]a, b[\longrightarrow \mathbb{R}$ une fonction différentiable. Si f admet un extremum local (minimum ou maximum) en un point $x_0 \in]a, b[$, alors

$$f'(x_0) = 0.$$

DÉRIVÉE ET EXTREMA



En un extremum local, la **tangente** au graphe de f est **horizontale**: sa pente $f'(x_0)$ est donc nulle.

DÉRIVÉE ET EXTREMA

Preuve: supposons que f admette un *maximum local* en x_0 , c'est-à-dire $f(x_0 + h) \leq f(x_0)$ pour tout h assez petit.

➤ Pour $h > 0$, on a $\frac{f(x_0 + h) - f(x_0)}{h} \leq 0$, et donc

$$f'(x_0) = \lim_{h \rightarrow 0^+} \frac{f(x_0 + h) - f(x_0)}{h} \leq 0.$$

➤ Pour $h < 0$, on a $\frac{f(x_0 + h) - f(x_0)}{h} \geq 0$ (numérateur ≤ 0 , dénominateur < 0), et donc

$$f'(x_0) = \lim_{h \rightarrow 0^-} \frac{f(x_0 + h) - f(x_0)}{h} \geq 0.$$

Comme f est différentiable en x_0 , ces deux limites valent toutes deux $f'(x_0)$. Ainsi $0 \leq f'(x_0) \leq 0$, et donc $f'(x_0) = 0$. Le cas d'un *minimum local* s'obtient en appliquant ce qui précède à $-f$. □

DÉRIVÉE ET EXTREMA

Preuve: supposons que f admette un *maximum local* en x_0 , c'est-à-dire $f(x_0 + h) \leq f(x_0)$ pour tout h assez petit.

- Pour $h > 0$, on a $\frac{f(x_0 + h) - f(x_0)}{h} \leq 0$, et donc

$$f'(x_0) = \lim_{h \rightarrow 0^+} \frac{f(x_0 + h) - f(x_0)}{h} \leq 0.$$

- Pour $h < 0$, on a $\frac{f(x_0 + h) - f(x_0)}{h} \geq 0$ (numérateur ≤ 0 , dénominateur < 0), et donc

$$f'(x_0) = \lim_{h \rightarrow 0^-} \frac{f(x_0 + h) - f(x_0)}{h} \geq 0.$$

Comme f est différentiable en x_0 , ces deux limites valent toutes deux $f'(x_0)$. Ainsi $0 \leq f'(x_0) \leq 0$, et donc $f'(x_0) = 0$. Le cas d'un *minimum local* s'obtient en appliquant ce qui précède à $-f$. □

DÉRIVÉE ET EXTREMA

Preuve: supposons que f admette un *maximum local* en x_0 , c'est-à-dire $f(x_0 + h) \leq f(x_0)$ pour tout h assez petit.

- Pour $h > 0$, on a $\frac{f(x_0 + h) - f(x_0)}{h} \leq 0$, et donc

$$f'(x_0) = \lim_{h \rightarrow 0^+} \frac{f(x_0 + h) - f(x_0)}{h} \leq 0.$$

- Pour $h < 0$, on a $\frac{f(x_0 + h) - f(x_0)}{h} \geq 0$ (numérateur ≤ 0 , dénominateur < 0), et donc

$$f'(x_0) = \lim_{h \rightarrow 0^-} \frac{f(x_0 + h) - f(x_0)}{h} \geq 0.$$

Comme f est différentiable en x_0 , ces deux limites valent toutes deux $f'(x_0)$. Ainsi $0 \leq f'(x_0) \leq 0$, et donc $f'(x_0) = 0$. Le cas d'un *minimum local* s'obtient en appliquant ce qui précède à $-f$. □

DÉRIVÉE ET EXTREMA

Preuve: supposons que f admette un *maximum local* en x_0 , c'est-à-dire $f(x_0 + h) \leq f(x_0)$ pour tout h assez petit.

- Pour $h > 0$, on a $\frac{f(x_0 + h) - f(x_0)}{h} \leq 0$, et donc

$$f'(x_0) = \lim_{h \rightarrow 0^+} \frac{f(x_0 + h) - f(x_0)}{h} \leq 0.$$

- Pour $h < 0$, on a $\frac{f(x_0 + h) - f(x_0)}{h} \geq 0$ (numérateur ≤ 0 , dénominateur < 0), et donc

$$f'(x_0) = \lim_{h \rightarrow 0^-} \frac{f(x_0 + h) - f(x_0)}{h} \geq 0.$$

Comme f est différentiable en x_0 , ces deux limites valent toutes deux $f'(x_0)$. Ainsi $0 \leq f'(x_0) \leq 0$, et donc $f'(x_0) = 0$. Le cas d'un *minimum local* s'obtient en appliquant ce qui précède à $-f$. □

DÉRIVÉE ET EXTREMA

Preuve: supposons que f admette un *maximum local* en x_0 , c'est-à-dire $f(x_0 + h) \leq f(x_0)$ pour tout h assez petit.

- Pour $h > 0$, on a $\frac{f(x_0 + h) - f(x_0)}{h} \leq 0$, et donc

$$f'(x_0) = \lim_{h \rightarrow 0^+} \frac{f(x_0 + h) - f(x_0)}{h} \leq 0.$$

- Pour $h < 0$, on a $\frac{f(x_0 + h) - f(x_0)}{h} \geq 0$ (numérateur ≤ 0 , dénominateur < 0), et donc

$$f'(x_0) = \lim_{h \rightarrow 0^-} \frac{f(x_0 + h) - f(x_0)}{h} \geq 0.$$

Comme f est différentiable en x_0 , ces deux limites valent toutes deux $f'(x_0)$. Ainsi $0 \leq f'(x_0) \leq 0$, et donc $f'(x_0) = 0$. Le cas d'un *minimum local* s'obtient en appliquant ce qui précède à $-f$. □

DÉRIVÉE ET EXTREMA

Preuve: supposons que f admette un *maximum local* en x_0 , c'est-à-dire $f(x_0 + h) \leq f(x_0)$ pour tout h assez petit.

- Pour $h > 0$, on a $\frac{f(x_0 + h) - f(x_0)}{h} \leq 0$, et donc

$$f'(x_0) = \lim_{h \rightarrow 0^+} \frac{f(x_0 + h) - f(x_0)}{h} \leq 0.$$

- Pour $h < 0$, on a $\frac{f(x_0 + h) - f(x_0)}{h} \geq 0$ (numérateur ≤ 0 , dénominateur < 0), et donc

$$f'(x_0) = \lim_{h \rightarrow 0^-} \frac{f(x_0 + h) - f(x_0)}{h} \geq 0.$$

Comme f est différentiable en x_0 , ces deux limites valent toutes deux $f'(x_0)$. Ainsi $0 \leq f'(x_0) \leq 0$, et donc $f'(x_0) = 0$. Le cas d'un *minimum local* s'obtient en appliquant ce qui précède à $-f$. □

DÉRIVÉE ET EXTREMA

Preuve: supposons que f admette un *maximum local* en x_0 , c'est-à-dire $f(x_0 + h) \leq f(x_0)$ pour tout h assez petit.

- Pour $h > 0$, on a $\frac{f(x_0 + h) - f(x_0)}{h} \leq 0$, et donc

$$f'(x_0) = \lim_{h \rightarrow 0^+} \frac{f(x_0 + h) - f(x_0)}{h} \leq 0.$$

- Pour $h < 0$, on a $\frac{f(x_0 + h) - f(x_0)}{h} \geq 0$ (numérateur ≤ 0 , dénominateur < 0), et donc

$$f'(x_0) = \lim_{h \rightarrow 0^-} \frac{f(x_0 + h) - f(x_0)}{h} \geq 0.$$

Comme f est différentiable en x_0 , ces deux limites valent toutes deux $f'(x_0)$. Ainsi $0 \leq f'(x_0) \leq 0$, et donc $f'(x_0) = 0$. Le cas d'un *minimum local* s'obtient en appliquant ce qui précède à $-f$. □

DÉRIVÉE ET EXTREMA

- ▶ Les points x_0 tels que $f'(x_0) = 0$ sont appelés *points critiques* (ou *points stationnaires*) de f .
- ▶ Le théorème dit donc: $\{\text{extrema locaux}\} \subseteq \{\text{points critiques}\}$.
- ▶ **Attention:** la réciproque est fausse! Par exemple, $f(x) = x^3$ vérifie $f'(0) = 0$, mais 0 n'est ni un min ni un max.

DÉRIVÉE ET EXTREMA


- ▶ Les points x_0 tels que $f'(x_0) = 0$ sont appelés *points critiques* (ou *points stationnaires*) de f .
- ▶ Le théorème dit donc: $\{\text{extrema locaux}\} \subseteq \{\text{points critiques}\}$.
- ▶ **Attention:** la réciproque est fausse! Par exemple, $f(x) = x^3$ vérifie $f'(0) = 0$, mais 0 n'est ni un min ni un max.

DÉRIVÉE ET EXTREMA

- ▶ Les points x_0 tels que $f'(x_0) = 0$ sont appelés *points critiques* (ou *points stationnaires*) de f .
- ▶ Le théorème dit donc: $\{\text{extrema locaux}\} \subseteq \{\text{points critiques}\}$.
- ▶ **Attention:** la réciproque est fausse! Par exemple, $f(x) = x^3$ vérifie $f'(0) = 0$, mais 0 n'est ni un min ni un max.

DÉRIVÉE ET EXTREMA

La réciproque est fausse: $f'(x_0) = 0$ n'entraîne pas que x_0 soit un extremum.



GRADIENT

- Soit $f : \mathbb{R}^N \longrightarrow \mathbb{R}$ une fonction différentiable (définition un peu différente). Le *gradient de f au point $x = (x_1, \dots, x_N)$* est le vecteur défini par

$$\nabla f(\mathbf{x}) := \begin{pmatrix} \frac{\partial f}{\partial x_1}(\mathbf{x}) \\ \vdots \\ \frac{\partial f}{\partial x_N}(\mathbf{x}) \end{pmatrix}$$

- La fonction

$$\begin{aligned} \nabla f : \mathbb{R}^N &\longrightarrow \mathbb{R}^N \\ x &\longmapsto \nabla f(x) \end{aligned}$$

est le *gradient* de f .

GRADIENT

- Soit $f : \mathbb{R}^N \longrightarrow \mathbb{R}$ une fonction différentiable (définition un peu différente). Le *gradient de f au point $x = (x_1, \dots, x_N)$* est le vecteur défini par

$$\nabla f(\mathbf{x}) := \begin{pmatrix} \frac{\partial f}{\partial x_1}(\mathbf{x}) \\ \vdots \\ \frac{\partial f}{\partial x_N}(\mathbf{x}) \end{pmatrix}$$


- La fonction

$$\begin{aligned} \nabla f : \mathbb{R}^N &\longrightarrow \mathbb{R}^N \\ \mathbf{x} &\longmapsto \nabla f(\mathbf{x}) \end{aligned}$$

est le *gradient* de f .


GRADIENT

- $\nabla f(\mathbf{x})$ est un vecteur de dimension N (“dans le sol”).
- Chaque dimension $\frac{\partial f}{\partial x_i}(\mathbf{x})$ de $\nabla f(\mathbf{x})$ représente le taux d'accroissement de f en $\mathbf{x}$ dans la direction $\mathbf{e}_i$.



GRADIENT

- ▶ $\nabla f(\mathbf{x})$ est un vecteur de dimension N (“dans le sol”).
- ▶ Chaque dimension $\frac{\partial f}{\partial x_i}(\mathbf{x})$ de $\nabla f(\mathbf{x})$ représente le taux d’accroissement de f en $\mathbf{x}$ dans la direction $\mathbf{e}_i$.



GRADIENT

- ▶ $\nabla f(x)$ représente la direction de la plus grande pente ascendante de f au point x .
- ▶ $\nabla f(x)$ is the direction of steepest ascent at x .
- ▶ De manière équivalente, $-\nabla f(x)$ représente la direction de la plus grande pente descendante de f au point x .
- ▶ $-\nabla f(x)$ is the direction of steepest descent at x .

GRADIENT

- ▶ $\nabla f(x)$ représente la direction de la plus grande pente ascendante de f au point x .
- ▶ $\nabla f(x)$ is the **direction of steepest ascent** at x .
- ▶ De manière équivalente, $-\nabla f(x)$ représente la direction de la plus grande pente descendante de f au point x .
- ▶ $-\nabla f(x)$ is the **direction of steepest descent** at x .

GRADIENT

- ▶ $\nabla f(x)$ représente la direction de la plus grande pente ascendante de f au point x .
- ▶ $\nabla f(x)$ is the **direction of steepest ascent** at x .
- ▶ De manière équivalente, $-\nabla f(x)$ représente la direction de la plus grande pente descendante de f au point x .
- ▶ $-\nabla f(x)$ is the **direction of steepest descent** at x .

GRADIENT

- ▶ $\nabla f(x)$ représente la direction de la plus grande pente ascendante de f au point x .
- ▶ $\nabla f(x)$ is the **direction of steepest ascent** at x .
- ▶ De manière équivalente, $-\nabla f(x)$ représente la direction de la plus grande pente descendante de f au point x .
- ▶ $-\nabla f(x)$ is the **direction of steepest descent** at x .

GRADIENT

- La *dérivée directionnelle* de f au point $\mathbf{x} = (x_1, \dots, x_N)$ selon la direction $\mathbf{v} \neq \mathbf{0}$ est définie par

$$\nabla_{\mathbf{v}} f(\mathbf{x}) := \lim_{h \rightarrow 0} \frac{f(\mathbf{x} + h\mathbf{v}) - f(\mathbf{x})}{h\|\mathbf{v}\|}.$$

- Intuitivement, $\nabla_{\mathbf{v}} f(\mathbf{x})$ représente le taux d'accroissement de f en $\mathbf{x}$ dans la direction $\mathbf{v}$.

GRADIENT

- Dire que le **gradient** est la **direction de la plus grande pente ascendante** signifie formellement que:
le **gradient** est le vecteur qui maximise la **dérivée directionnelle**.

THEOREM

Soit $f : \mathbb{R}^N \rightarrow \mathbb{R}$ une fonction différentiable. Pour tout $x \in \mathbb{R}^N$, on a:

$$\nabla f(x) \in \arg \max_{v \neq 0} \nabla_v f(x).$$

GRADIENT

Preuve: On peut montrer que

$$\nabla_v f(x) = \nabla f(x) \cdot \frac{v}{\|v\|} = \|\nabla f(x)\| \cdot \frac{\|v\|}{\|v\|} \cdot \cos \theta = \|\nabla f(x)\| \cdot \cos(\theta)$$

où $\theta := \theta(\nabla f(x), v)$.

Ainsi, $\nabla_v f(x)$ est maximal lorsque $\cos(\theta) = 1$, i.e., lorsque v est parallèle à $\nabla f(x)$. Donc en particulier,

$$\nabla f(x) \in \arg \max_{v \neq 0} \nabla_v f(x).$$



GRADIENT

Preuve: On peut montrer que

$$\nabla_v f(x) = \nabla f(x) \cdot \frac{v}{\|v\|} = \|\nabla f(x)\| \cdot \frac{\|v\|}{\|v\|} \cdot \cos \theta = \|\nabla f(x)\| \cdot \cos(\theta)$$

où $\theta := \theta(\nabla f(x), v)$.

Ainsi, $\nabla_v f(x)$ est maximal lorsque $\cos(\theta) = 1$, i.e., lorsque v est parallèle à $\nabla f(x)$. Donc en particulier,

$$\nabla f(x) \in \arg \max_{v \neq 0} \nabla_v f(x).$$



GRADIENT

Preuve: On peut montrer que

$$\nabla_v f(x) = \nabla f(x) \cdot \frac{v}{\|v\|} = \|\nabla f(x)\| \cdot \frac{\|v\|}{\|v\|} \cdot \cos \theta = \|\nabla f(x)\| \cdot \cos(\theta)$$

où $\theta := \theta(\nabla f(x), v)$.

Ainsi, $\nabla_v f(x)$ est maximal lorsque $\cos(\theta) = 1$, i.e., lorsque v est parallèle à $\nabla f(x)$. Donc en particulier,

$$\nabla f(x) \in \arg \max_{v \neq 0} \nabla_v f(x).$$



GRADIENT

Preuve: On peut montrer que

$$\nabla_v f(\mathbf{x}) = \nabla f(\mathbf{x}) \cdot \frac{\mathbf{v}}{\|\mathbf{v}\|} = \|\nabla f(\mathbf{x})\| \cdot \frac{\|\mathbf{v}\|}{\|\mathbf{v}\|} \cdot \cos \theta = \|\nabla f(\mathbf{x})\| \cdot \cos(\theta)$$

où $\theta := \theta(\nabla f(\mathbf{x}), \mathbf{v})$.

Ainsi, $\nabla_v f(\mathbf{x})$ est maximal lorsque $\cos(\theta) = 1$, i.e., lorsque $\mathbf{v}$ est parallèle à $\nabla f(\mathbf{x})$. Donc en particulier,

$$\nabla f(\mathbf{x}) \in \arg \max_{\mathbf{v} \neq \mathbf{0}} \nabla_v f(\mathbf{x}).$$



GRADIENT: REMARQUES

- La dérivée directionnelle $\nabla_v f(x)$ ne dépend que de la *direction* de v , et non de sa longueur:

$$\nabla_{\lambda v} f(x) = \nabla_v f(x) \quad \text{pour tout } \lambda > 0.$$

Tout multiple positif $\lambda \nabla f(x)$ est donc aussi un maximiseur.

- La **valeur maximale** de la dérivée directionnelle est

$$\max_{v \neq 0} \nabla_v f(x) = \|\nabla f(x)\|,$$

c'est-à-dire la *pente* de la plus grande pente ascendante.

- Si $\nabla f(x) = 0$, alors **toutes** les dérivées directionnelles en x sont nulles: le point x est *plat* dans toutes les directions.

GRADIENT: REMARQUES

- La dérivée directionnelle $\nabla_v f(x)$ ne dépend que de la *direction* de v , et non de sa longueur:

$$\nabla_{\lambda v} f(x) = \nabla_v f(x) \quad \text{pour tout } \lambda > 0.$$

Tout multiple positif $\lambda \nabla f(x)$ est donc aussi un maximiseur.

- La **valeur maximale** de la dérivée directionnelle est

$$\max_{v \neq 0} \nabla_v f(x) = \|\nabla f(x)\|,$$

c'est-à-dire la *pente* de la plus grande pente ascendante.

- Si $\nabla f(x) = 0$, alors **toutes** les dérivées directionnelles en x sont nulles: le point x est *plat* dans toutes les directions.

GRADIENT: REMARQUES

- La dérivée directionnelle $\nabla_v f(x)$ ne dépend que de la *direction* de v , et non de sa longueur:

$$\nabla_{\lambda v} f(x) = \nabla_v f(x) \quad \text{pour tout } \lambda > 0.$$

Tout multiple positif $\lambda \nabla f(x)$ est donc aussi un maximiseur.

- La **valeur maximale** de la dérivée directionnelle est

$$\max_{v \neq 0} \nabla_v f(x) = \|\nabla f(x)\|,$$

c'est-à-dire la *pente* de la plus grande pente ascendante.

- Si $\nabla f(x) = 0$, alors **toutes** les dérivées directionnelles en x sont nulles: le point x est *plat* dans toutes les directions.

GRADIENT: EXERCICES

Calculer le gradient des fonctions suivantes:

(A) $f(x, y) = x^2 + 3y^2 - 4x + 2y$

(B) $f(x, y) = x^2y + y^3$

(C) $f(x, y) = e^{-(x^2+y^2)}$

(D) $f(x, y) = \ln(1 + x^2 + y^2)$

(E) $f(x, y, z) = xyz + x^2z$

GRADIENT: EXERCICES

Calculer le gradient des fonctions suivantes (elles apparaissent constamment en machine learning):

(F) $f(\mathbf{w}) = \|\mathbf{w}\|^2 = \sum_{i=1}^N w_i^2$

(G) $f(\mathbf{w}) = \mathbf{w} \cdot \mathbf{x} = \sum_{i=1}^N w_i x_i$, où $\mathbf{x}$ est *fixé*

(H) $L(\mathbf{w}) = \sum_{i=1}^n (y_i - \mathbf{w} \cdot \mathbf{x}_i)^2$, où les $(\mathbf{x}_i, y_i)$ sont *fixés*
(erreur quadratique de la régression linéaire)

GRADIENT: CORRIGÉS

$$(A) \quad \nabla f(x, y) = \begin{pmatrix} 2x - 4 \\ 6y + 2 \end{pmatrix}$$

$$(B) \quad \nabla f(x, y) = \begin{pmatrix} 2xy \\ x^2 + 3y^2 \end{pmatrix}$$

$$(C) \quad \nabla f(x, y) = \begin{pmatrix} -2x e^{-(x^2+y^2)} \\ -2y e^{-(x^2+y^2)} \end{pmatrix} = -2 e^{-(x^2+y^2)} \begin{pmatrix} x \\ y \end{pmatrix}$$

$$(D) \quad \nabla f(x, y) = \frac{1}{1 + x^2 + y^2} \begin{pmatrix} 2x \\ 2y \end{pmatrix}$$

$$(E) \quad \nabla f(x, y, z) = \begin{pmatrix} yz + 2xz \\ xz \\ xy + x^2 \end{pmatrix}$$

GRADIENT: CORRIGÉS

$$(F) \quad \frac{\partial f}{\partial w_i} = 2w_i, \quad \text{donc } \nabla f(\mathbf{w}) = 2\mathbf{w}.$$

$$(G) \quad \frac{\partial f}{\partial w_i} = x_i, \quad \text{donc } \nabla f(\mathbf{w}) = \mathbf{x}.$$

(H) par la **chain rule**, pour chaque composante w_j :

$$\frac{\partial L}{\partial w_j} = \sum_{i=1}^n 2(y_i - \mathbf{w} \cdot \mathbf{x}_i) \cdot (-x_{ij}) = -2 \sum_{i=1}^n (y_i - \mathbf{w} \cdot \mathbf{x}_i) x_{ij},$$

donc

$$\nabla L(\mathbf{w}) = -2 \sum_{i=1}^n (y_i - \mathbf{w} \cdot \mathbf{x}_i) \mathbf{x}_i.$$

GRADIENT ET EXTREMA

- Le théorème de Fermat se généralise directement au cas de plusieurs variables.

THEOREM (FERMAT, CAS MULTIDIMENSIONNEL)

Soit $f : \mathbb{R}^N \rightarrow \mathbb{R}$ une fonction différentiable. Si f admet un extremum local (minimum ou maximum) en un point $x_0 \in \mathbb{R}^N$, alors

$$\nabla f(x_0) = 0.$$

GRADIENT ET EXTREMA

- Le théorème de Fermat se généralise directement au cas de plusieurs variables.

THEOREM (FERMAT, CAS MULTIDIMENSIONNEL)

Soit $f : \mathbb{R}^N \rightarrow \mathbb{R}$ une fonction différentiable. Si f admet un extremum local (minimum ou maximum) en un point $x_0 \in \mathbb{R}^N$, alors

$$\nabla f(x_0) = 0.$$

GRADIENT ET EXTREMA

- Le théorème de Fermat se généralise directement au cas de plusieurs variables.


THEOREM (FERMAT, CAS MULTIDIMENSIONNEL)

Soit $f : \mathbb{R}^N \longrightarrow \mathbb{R}$ une fonction différentiable. Si f admet un extremum local (minimum ou maximum) en un point $x_0 \in \mathbb{R}^N$, alors

$$\nabla f(x_0) = \mathbf{0}.$$

GRADIENT ET EXTREMA

En un extremum local, le **plan tangent** à la surface est **horizontal**: la fonction y est plate dans toutes les directions, i.e. $\nabla f = \vec{0}$.



GRADIENT ET EXTREMA

Preuve: l'idée est de se ramener au cas d'une seule variable.

- Fixons $i \in \{1, \dots, N\}$ et considérons la fonction d'une seule variable

$$g_i : \mathbb{R} \longrightarrow \mathbb{R}, \quad g_i(t) := f(x_0 + t e_i).$$

- Si f admet un extremum local en x_0 , alors g_i admet un extremum local en $t = 0$.

- Par définition de la dérivée normale et partielle, on a

$$\begin{aligned} g_i'(0) &= \lim_{t \rightarrow 0} \frac{f(x_0 + (t + 0)e_i) - f(x_0 + 0e_i)}{t - 0} \\ &= \lim_{t \rightarrow 0} \frac{f(x_0 + t e_i) - f(x_0)}{t} = \frac{\partial f}{\partial e_i}(x_0). \end{aligned}$$

- Le théorème de Fermat (cas $N = 1$) appliqué à g_i donne $g_i'(0) = 0$, d'où $\frac{\partial f}{\partial e_i}(x_0) = 0$.

- Ceci vaut pour tout i , donc toutes les composantes de $\nabla f(x_0)$ sont nulles.

GRADIENT ET EXTREMA

Preuve: l'idée est de se ramener au cas d'une seule variable.

- Fixons $i \in \{1, \dots, N\}$ et considérons la fonction d'**une seule variable**

$$g_i : \mathbb{R} \longrightarrow \mathbb{R}, \quad g_i(t) := f(x_0 + t e_i).$$

- Si f admet un extremum local en x_0 , alors g_i admet un extremum local en $t = 0$.
- Par définition de la dérivée normale et partielle, on a

$$\begin{aligned} g'_i(0) &= \lim_{h \rightarrow 0} \frac{f(x_0 + (0+h)e_i) - f(x_0 + 0e_i)}{h} \\ &= \lim_{h \rightarrow 0} \frac{f(x_0 + h e_i) - f(x_0)}{h} =: \frac{\partial f}{\partial x_i}(x_0). \end{aligned}$$

- Le théorème de Fermat (cas $N = 1$) appliqué à g_i donne $g'_i(0) = 0$, c'est-à-dire $\frac{\partial f}{\partial x_i}(x_0) = 0$.
- Ceci vaut pour tout i , donc toutes les composantes de $\nabla f(x_0)$ sont nulles.

GRADIENT ET EXTREMA

Preuve: l'idée est de se ramener au cas d'une seule variable.

- Fixons $i \in \{1, \dots, N\}$ et considérons la fonction d'**une seule variable**

$$g_i : \mathbb{R} \longrightarrow \mathbb{R}, \quad g_i(t) := f(x_0 + t e_i).$$

- Si f admet un extremum local en x_0 , alors g_i admet un extremum local en $t = 0$.
- Par définition de la dérivée normale et partielle, on a

$$\begin{aligned} g_i'(0) &= \lim_{h \rightarrow 0} \frac{f(x_0 + (0+h)e_i) - f(x_0 + 0e_i)}{h} \\ &= \lim_{h \rightarrow 0} \frac{f(x_0 + h e_i) - f(x_0)}{h} =: \frac{\partial f}{\partial x_i}(x_0). \end{aligned}$$

- Le théorème de Fermat (cas $N = 1$) appliqué à g_i donne $g_i'(0) = 0$, c'est-à-dire $\frac{\partial f}{\partial x_i}(x_0) = 0$.
- Ceci vaut pour tout i , donc toutes les composantes de $\nabla f(x_0)$ sont nulles.

GRADIENT ET EXTREMA

Preuve: l'idée est de se ramener au cas d'une seule variable.

- Fixons $i \in \{1, \dots, N\}$ et considérons la fonction d'**une seule variable**

$$g_i : \mathbb{R} \longrightarrow \mathbb{R}, \quad g_i(t) := f(\mathbf{x}_0 + t \mathbf{e}_i).$$

- Si f admet un extremum local en $\mathbf{x}_0$, alors g_i admet un extremum local en $t = 0$.
- Par définition de la dérivée normale et partielle, on a

$$\begin{aligned} g_i'(0) &= \lim_{h \rightarrow 0} \frac{f(\mathbf{x}_0 + (0+h) \mathbf{e}_i) - f(\mathbf{x}_0 + 0 \mathbf{e}_i)}{h} \\ &= \lim_{h \rightarrow 0} \frac{f(\mathbf{x}_0 + h \mathbf{e}_i) - f(\mathbf{x}_0)}{h} =: \frac{\partial f}{\partial x_i}(\mathbf{x}_0). \end{aligned}$$

- Le théorème de Fermat (cas $N = 1$) appliqué à g_i donne $g_i'(0) = 0$, c'est-à-dire $\frac{\partial f}{\partial x_i}(\mathbf{x}_0) = 0$.
- Ceci vaut pour tout i , donc toutes les composantes de $\nabla f(\mathbf{x}_0)$ sont nulles.

GRADIENT ET EXTREMA

Preuve: l'idée est de se ramener au cas d'une seule variable.

- Fixons $i \in \{1, \dots, N\}$ et considérons la fonction d'**une seule variable**

$$g_i : \mathbb{R} \longrightarrow \mathbb{R}, \quad g_i(t) := f(\mathbf{x}_0 + t \mathbf{e}_i).$$

- Si f admet un extremum local en $\mathbf{x}_0$, alors g_i admet un extremum local en $t = 0$.
- Par définition de la dérivée normale et partielle, on a

$$\begin{aligned} g_i'(0) &= \lim_{h \rightarrow 0} \frac{f(\mathbf{x}_0 + (0+h) \mathbf{e}_i) - f(\mathbf{x}_0 + 0 \mathbf{e}_i)}{h} \\ &= \lim_{h \rightarrow 0} \frac{f(\mathbf{x}_0 + h \mathbf{e}_i) - f(\mathbf{x}_0)}{h} =: \frac{\partial f}{\partial x_i}(\mathbf{x}_0). \end{aligned}$$

- Le théorème de Fermat (cas $N = 1$) appliqué à g_i donne $g_i'(0) = 0$, c'est-à-dire $\frac{\partial f}{\partial x_i}(\mathbf{x}_0) = 0$.
- Ceci vaut pour tout i , donc toutes les composantes de $\nabla f(\mathbf{x}_0)$ sont nulles.

GRADIENT ET EXTREMA

- ▶ Les points x_0 tels que $\nabla f(x_0) = \mathbf{0}$ sont les *points critiques* de f .
- ▶ Comme en dimension 1, la réciproque est fautive: un point critique n'est pas nécessairement un extremum.
- ▶ En dimension $N \geq 2$, un point critique peut être:
 - un minimum local,
 - un maximum local,
 - ou un point-selle (selle point).

GRADIENT ET EXTREMA

- ▶ Les points x_0 tels que $\nabla f(x_0) = \mathbf{0}$ sont les *points critiques* de f .
- ▶ Comme en dimension 1, la réciproque est fausse: un point critique n'est pas nécessairement un extremum.
- ▶ En dimension $N \geq 2$, un point critique peut être:
 - ▶ un minimum local,
 - ▶ un maximum local,
 - ▶ ou un point-selle (ou de selle).

GRADIENT ET EXTREMA

- ▶ Les points x_0 tels que $\nabla f(x_0) = \mathbf{0}$ sont les *points critiques* de f .
- ▶ Comme en dimension 1, la réciproque est fausse: un point critique n'est pas nécessairement un extremum.
- ▶ En dimension $N \geq 2$, un point critique peut être:
 - ▶ un **minimum local**,
 - ▶ un **maximum local**,
 - ▶ ou un **point selle** (*saddle point*).

GRADIENT ET EXTREMA

- ▶ Les points x_0 tels que $\nabla f(x_0) = \mathbf{0}$ sont les *points critiques* de f .
- ▶ Comme en dimension 1, la réciproque est fausse: un point critique n'est pas nécessairement un extremum.
- ▶ En dimension $N \geq 2$, un point critique peut être:
 - ▶ un **minimum local**,
 - ▶ un **maximum local**,
 - ▶ ou un **point selle** (*saddle point*).

GRADIENT ET EXTREMA

- ▶ Les points x_0 tels que $\nabla f(x_0) = \mathbf{0}$ sont les *points critiques* de f .
- ▶ Comme en dimension 1, la réciproque est fausse: un point critique n'est pas nécessairement un extremum.
- ▶ En dimension $N \geq 2$, un point critique peut être:
 - ▶ un **minimum local**,
 - ▶ un **maximum local**,
 - ▶ ou un **point selle** (*saddle point*).

GRADIENT ET EXTREMA

- ▶ Les points x_0 tels que $\nabla f(x_0) = \mathbf{0}$ sont les *points critiques* de f .
- ▶ Comme en dimension 1, la réciproque est fausse: un point critique n'est pas nécessairement un extremum.
- ▶ En dimension $N \geq 2$, un point critique peut être:
 - ▶ un **minimum local**,
 - ▶ un **maximum local**,
 - ▶ ou un **point selle** (*saddle point*).

GRADIENT ET EXTREMA

Exemple: $f(x, y) = x^2 - y^2$ a un **point selle** en $(0, 0)$, puisque $\nabla f(0, 0) = \mathbf{0}$ sans que $(0, 0)$ soit un minimum ni un maximum.

