

NAIVE BAYES CLASSIFIER

Jérémie Cabessa

Laboratoire DAVID, UVSQ

INTRODUCTION

- ▶ Dans le cadre de l'**apprentissage supervisé**, on distingue deux types de méthodes:
- ▶ Méthodes de régression
La variable d'output (réponse) est **quantitative**.
- ▶ Méthodes de classification
La variable d'output (réponse) est **qualitative**.

INTRODUCTION

- ▶ Dans le cadre de l'**apprentissage supervisé**, on distingue deux types de méthodes:
- ▶ **Méthodes de régression**
La variable d'output (réponse) est **quantitative**.
- ▶ Méthodes de classification
La variable d'output (réponse) est **qualitative**.

INTRODUCTION

- ▶ Dans le cadre de l'**apprentissage supervisé**, on distingue deux types de méthodes:
- ▶ **Méthodes de régression**
La variable d'output (réponse) est **quantitative**.
- ▶ **Méthodes de classification**
La variable d'output (réponse) est **qualitative**.

INTRODUCTION

- ▶ Un **classifieur de Bayes naïf (naive Bayes classifier)** est une méthode de classification basée sur le *théorème de Bayes*.
- ▶ Un naive Bayes classifier possède un petit nombre de paramètres à estimer: linéaire par rapport au nombre de variables.
- ▶ L'apprentissage de ces paramètres admet une solution analytique (closed-form solution) calculable en temps linéaire.

INTRODUCTION

- ▶ Un **classifieur de Bayes naïf (naive Bayes classifier)** est une méthode de classification basée sur le *théorème de Bayes*.
- ▶ Un naive Bayes classifier possède un petit nombre de paramètres à estimer: linéaire par rapport au nombre de variables.
- ▶ L'apprentissage de ces paramètres admet une solution analytique (closed-form solution) calculable en temps linéaire.

INTRODUCTION

- ▶ Un **classifieur de Bayes naïf (naive Bayes classifier)** est une méthode de classification basée sur le *théorème de Bayes*.
- ▶ Un naive Bayes classifier possède un petit nombre de paramètres à estimer: linéaire par rapport au nombre de variables.
- ▶ L'apprentissage de ces paramètres admet une solution analytique (closed-form solution) calculable en temps linéaire.

PROBABILITÉS CONDITIONNELLES

- ▶ Soit p une mesure de probabilité et A et B deux évènements de probabilité non nulle.
- ▶ La *probabilité conditionnelle* de A sachant B est

$$p(A \mid B) = \frac{p(A \cap B)}{p(B)}$$

- ▶ $p(A \mid B)$ représente *la probabilité que l'évènement A advienne sachant que l'évènement B a eu lieu.*

PROBABILITÉS CONDITIONNELLES

- ▶ Soit p une mesure de probabilité et A et B deux évènements de probabilité non nulle.
- ▶ La *probabilité conditionnelle* de A sachant B est

$$p(A \mid B) = \frac{p(A \cap B)}{p(B)}$$

- ▶ $p(A \mid B)$ représente *la probabilité que l'évènement A advienne sachant que l'évènement B a eu lieu.*

PROBABILITÉS CONDITIONNELLES

- ▶ Soit p une mesure de probabilité et A et B deux évènements de probabilité non nulle.
- ▶ La *probabilité conditionnelle* de A sachant B est

$$p(A \mid B) = \frac{p(A \cap B)}{p(B)}$$

- ▶ $p(A \mid B)$ représente *la probabilité que l'évènement A advienne sachant que l'évènement B a eu lieu.*

THÉORÈME DE BAYES

- La formule de la *probabilité conditionnelle* implique les relations suivantes:

$$p(A | B) = \frac{p(A \cap B)}{p(B)} \quad \Rightarrow \quad p(A \cap B) = p(A | B) p(B)$$

$$p(B | A) = \frac{p(B \cap A)}{p(A)} = \frac{p(A \cap B)}{p(A)} \quad \Rightarrow \quad p(A \cap B) = p(B | A) p(A)$$

Donc, $p(A \cap B)$ peut être calculé en utilisant le théorème de Bayes:

$$p(A | B)p(B) = p(B | A)p(A)$$

$$p(A \cap B) = p(B | A)p(A)$$

THÉORÈME DE BAYES

- La formule de la *probabilité conditionnelle* implique les relations suivantes:

$$p(A | B) = \frac{p(A \cap B)}{p(B)} \quad \Rightarrow \quad p(A \cap B) = p(A | B) p(B)$$

$$p(B | A) = \frac{p(B \cap A)}{p(A)} = \frac{p(A \cap B)}{p(A)} \quad \Rightarrow \quad p(A \cap B) = p(B | A) p(A)$$

Donc, $p(A \cap B)$ est équivalent à l'intersection impliquant le théorème de Bayes

$$p(A | B)p(B) = p(B | A)p(A)$$

$$p(A | B) = \frac{p(B | A)p(A)}{p(B)}$$

THÉORÈME DE BAYES

- La formule de la *probabilité conditionnelle* implique les relations suivantes:

$$p(A | B) = \frac{p(A \cap B)}{p(B)} \quad \Rightarrow \quad p(A \cap B) = p(A | B) p(B)$$

$$p(B | A) = \frac{p(B \cap A)}{p(A)} = \frac{p(A \cap B)}{p(A)} \quad \Rightarrow \quad p(A \cap B) = p(B | A) p(A)$$

- Les equations ci-dessus impliquent le théorème de Bayes:

$$p(A | B) p(B) = p(B | A) p(A)$$

ssi

$$p(A | B) = \frac{p(B | A) p(A)}{p(B)}$$

THÉORÈME DE BAYES

- La formule de la *probabilité conditionnelle* implique les relations suivantes:

$$p(A | B) = \frac{p(A \cap B)}{p(B)} \quad \Rightarrow \quad p(A \cap B) = p(A | B) p(B)$$

$$p(B | A) = \frac{p(B \cap A)}{p(A)} = \frac{p(A \cap B)}{p(A)} \quad \Rightarrow \quad p(A \cap B) = p(B | A) p(A)$$

► Les equations ci-dessus impliquent le théorème de Bayes:

$$p(A | B) p(B) = p(B | A) p(A)$$

ssi

$$p(A | B) = \frac{p(B | A) p(A)}{p(B)}$$

THÉORÈME DE BAYES

- La formule de la *probabilité conditionnelle* implique les relations suivantes:

$$p(A | B) = \frac{p(A \cap B)}{p(B)} \quad \Rightarrow \quad p(A \cap B) = p(A | B) p(B)$$

$$p(B | A) = \frac{p(B \cap A)}{p(A)} = \frac{p(A \cap B)}{p(A)} \quad \Rightarrow \quad p(A \cap B) = p(B | A) p(A)$$

- Les equations ci-dessus impliquent le **théorème de Bayes**:

$$p(A | B) p(B) = p(B | A) p(A)$$

ssi

$$p(A | B) = \frac{p(B | A) p(A)}{p(B)}$$

THÉORÈME DE BAYES

- ▶ Le théorème de Bayes s'utilise lorsqu'on désire calculer $p(A | B)$ mais que cette quantité est difficile à estimer à partir des data.

$$p(A | B) = \frac{p(B | A) p(A)}{p(B)}$$

- ▶ Il est alors possible de calculer $p(A | B)$ à partir de $p(B | A)$, qui est potentiellement plus facile à estimer à partir des data.
- ▶ En résumé, la probabilité conditionnelle $p(A | B)$ peut s'exprimer à partir de sa probabilité conditionnelle "inverse" $p(B | A)$.

THÉORÈME DE BAYES

- ▶ Le théorème de Bayes s'utilise lorsqu'on désire calculer $p(A | B)$ mais que cette quantité est difficile à estimer à partir des data.

$$p(A | B) = \frac{p(B | A) p(A)}{p(B)}$$

- ▶ Il est alors possible de calculer $p(A | B)$ à partir de $p(B | A)$, qui est potentiellement plus facile à estimer à partir des data.
- ▶ En résumé, la probabilité conditionnelle $p(A | B)$ peut s'exprimer à partir de sa probabilité conditionnelle "inverse" $p(B | A)$.

THÉORÈME DE BAYES

- ▶ Le théorème de Bayes s'utilise lorsqu'on désire calculer $p(A | B)$ mais que cette quantité est difficile à estimer à partir des data.

$$p(A | B) = \frac{p(B | A) p(A)}{p(B)}$$

- ▶ Il est alors possible de calculer $p(A | B)$ à partir de $p(B | A)$, qui est potentiellement plus facile à estimer à partir des data.
- ▶ En résumé, la probabilité conditionnelle $p(A | B)$ peut s'exprimer à partir de sa probabilité conditionnelle "inverse" $p(B | A)$.

THÉORÈME DE BAYES

- ▶ Basé sur une étude de Kahneman & Tversky (1974):

Steve est d'un tempérament doux, timide, plutôt introverti. Bien qu'il soit très aimable, il semble montrer peu d'attention envers les autres personnes. Il a tendance à être très ordonnée et montre un intérêt marqué pour tout ce qui est de l'ordre du détail.

- ▶ Laquelle de ces affirmations semble la plus plausible?

- (A) Steve est libraire.
- (B) Steve est agriculteur.

THÉORÈME DE BAYES

- ▶ Basé sur une étude de Kahneman & Tversky (1974):

Steve est d'un tempérament doux, timide, plutôt introverti. Bien qu'il soit très aimable, il semble montrer peu d'attention envers les autres personnes. Il a tendance à être très ordonnée et montre un intérêt marqué pour tout ce qui est de l'ordre du détail.

- ▶ Laquelle de ces affirmations semble la plus plausible?

- (A) Steve est libraire.
- (B) Steve est agriculteur.

THÉORÈME DE BAYES

- ▶ Basé sur une étude de Kahneman & Tversky (1974):
Steve est d'un tempérament doux, timide, plutôt introverti. Bien qu'il soit très aimable, il semble montrer peu d'attention envers les autres personnes. Il a tendance à être très ordonnée et montre un intérêt marqué pour tout ce qui est de l'ordre du détail.
- ▶ Laquelle de ces affirmations semble la plus plausible?
- (A) Steve est libraire.
- (B) Steve est agriculteur.

THÉORÈME DE BAYES

- ▶ Basé sur une étude de Kahneman & Tversky (1974):
Steve est d'un tempérament doux, timide, plutôt introverti. Bien qu'il soit très aimable, il semble montrer peu d'attention envers les autres personnes. Il a tendance à être très ordonnée et montre un intérêt marqué pour tout ce qui est de l'ordre du détail.
- ▶ Laquelle de ces affirmations semble la plus plausible?
 - (A) Steve est libraire.
 - (B) Steve est agriculteur.

THÉORÈME DE BAYES

- ▶ Basé sur une étude de Kahneman & Tversky (1974):
Steve est d'un tempérament doux, timide, plutôt introverti. Bien qu'il soit très aimable, il semble montrer peu d'attention envers les autres personnes. Il a tendance à être très ordonnée et montre un intérêt marqué pour tout ce qui est de l'ordre du détail.
 - ▶ Laquelle de ces affirmations semble la plus plausible?
- (A) Steve est libraire.
- (B) Steve est agriculteur.

THÉORÈME DE BAYES

- ▶ Basé sur une étude de Kahneman & Tversky (1974):
Steve est d'un tempérament doux, timide, plutôt introverti. Bien qu'il soit très aimable, il semble montrer peu d'attention envers les autres personnes. Il a tendance à être très ordonnée et montre un intérêt marqué pour tout ce qui est de l'ordre du détail.
- ▶ Laquelle de ces affirmations semble la plus plausible?
 - (A) Steve est libraire.
 - (B) Steve est agriculteur.

THÉORÈME DE BAYES

- ▶ Si on laisse de côté la question des *stéréotypes* sur différentes professions, la plupart des gens répondent en général que:
 - ▶ *Steve a bien plus de chance d'être libraire qu'agriculteur...*
 - ▶ Mais cette réponse est *irrationnelle*... Pourquoi?

THÉORÈME DE BAYES

- ▶ Si on laisse de côté la question des *stéréotypes* sur différentes professions, la plupart des gens répondent en général que:
- ▶ *Steve a bien plus de chance d'être libraire qu'agriculteur...*
- ▶ Mais cette réponse est *irrationnelle...* Pourquoi?

THÉORÈME DE BAYES

- ▶ Si on laisse de côté la question des *stéréotypes* sur différentes professions, la plupart des gens répondent en général que:
- ▶ *Steve a bien plus de chance d'être libraire qu'agriculteur...*
- ▶ Mais cette réponse est *irrationnelle*... Pourquoi?

THÉORÈME DE BAYES

- ▶ Les gens oublient totalement de prendre en compte la proportion de libraires et d'agriculteurs dans la population!
- ▶ Aux USA, il semble qu'il y ait bien plus d'agriculteurs que de libraires (en tout cas dans les années 70)!
- ▶ Supposons que la population compte 20 fois plus d'agriculteurs que de libraires: même si vous voyez un homme avec une hache, il sera encore plus probable qu'il soit un agriculteur qu'un libraire.

THÉORÈME DE BAYES

- ▶ Les gens oublient totalement de prendre en compte la proportion de libraires et d'agriculteurs dans la population!
- ▶ Aux USA, il semble qu'il y ait bien plus d'agriculteurs que de libraires (en tout cas dans les années 70)!
- ▶ Supposons que la population compte 20 fois plus d'agriculteurs que de libraires: $P(A) = 20P(B)$.
Cela signifie qu'il y a 20 fois plus de chances qu'il soit agriculteur que

THÉORÈME DE BAYES

- ▶ Les gens oublient totalement de prendre en compte la proportion de libraires et d'agriculteurs dans la population!
- ▶ Aux USA, il semble qu'il y ait bien plus d'agriculteurs que de libraires (en tout cas dans les années 70)!
- ▶ Supposons que la population compte 20 fois plus d'agriculteurs que de libraires: même si Steve semble montrer des "traits" de libraires, il reste assez peu probable qu'il soit effectivement libraire...

THÉORÈME DE BAYES


- ▶ Les gens oublient totalement de prendre en compte la proportion de libraires et d'agriculteurs dans la population!
- ▶ Aux USA, il semble qu'il y ait bien plus d'agriculteurs que de libraires (en tout cas dans les années 70)!
- ▶ Supposons que la population compte 20 fois plus d'agriculteurs que de libraires: même si Steve semble montrer des "traits" de libraires, il reste assez peu probable qu'il soit effectivement libraire...

THÉORÈME DE BAYES

- ▶ Les gens oublient totalement de prendre en compte la proportion de libraires et d'agriculteurs dans la population!
- ▶ Aux USA, il semble qu'il y ait bien plus d'agriculteurs que de libraires (en tout cas dans les années 70)!
- ▶ Supposons que la population compte 20 fois plus d'agriculteurs que de libraires: même si Steve semble montrer des "traits" de libraires, il reste assez peu probable qu'il soit effectivement libraire...


THÉORÈME DE BAYES

- ▶ On a 10 libraires et 200 agriculteurs.
- ▶ 80% des libraires et 10% des agriculteurs correspondent à la description (situation où les stéréotypes sont “justes”).
- ▶ $p(\text{libraire} \mid \text{description}) = \frac{8}{8+20} \approx 28.57\%$



THÉORÈME DE BAYES

- ▶ On a 10 libraires et 200 agriculteurs.
- ▶ 80% des libraires et 10% des agriculteurs correspondent à la description (situation où les stéréotypes sont “justes”).
- ▶ $p(\text{libraire} \mid \text{description}) = \frac{8}{8+20} \approx 28.57\%$



THÉORÈME DE BAYES

- ▶ On a 10 libraires et 200 agriculteurs.
- ▶ 80% des libraires et 10% des agriculteurs correspondent à la description (situation où les stéréotypes sont “justes”).
- ▶ $p(\text{libraire} \mid \text{description}) = \frac{8}{8+20} \approx 28.57\%$



80% of librarians
fit the description

10% of farmers fit the description



THÉORÈME DE BAYES

- ▶ **Hypothèse H :** Steve est libraire.
- ▶ **Évidence E :** Steve est d'un tempérament doux, timide, ...
- ▶ **Prior:** Probabilité de l'hypothèse avant de recevoir une évidence: $p(H) = \frac{10}{210} = \frac{1}{21} \approx 4.76\%$
- ▶ **Likelihood:** Probabilité de l'évidence étant donné que l'hypothèse est vraie $p(E | H) = 80\%$.
- ▶ **(Likelihood bis):** Probabilité de l'évidence étant donné que l'hypothèse est fausse $p(E | \neg H) = 10\%$.
- ▶ **Posterior:** Probabilité de l'hypothèse étant donné l'évidence $p(H | E) = \frac{8}{8+20} \approx 28.57\%$ (ce que l'on cherche).

THÉORÈME DE BAYES

- ▶ **Hypothèse H :** Steve est libraire.
- ▶ **Évidence E :** Steve est d'un tempérament doux, timide, ...
- ▶ **Prior:** Probabilité de l'hypothèse avant de recevoir une évidence: $p(H) = \frac{10}{210} = \frac{1}{21} \approx 4.76\%$
- ▶ **Likelihood:** Probabilité de l'évidence étant donné que l'hypothèse est vraie $p(E | H) = 80\%$.
- ▶ **(Likelihood bis):** Probabilité de l'évidence étant donné que l'hypothèse est fausse $p(E | \neg H) = 10\%$.
- ▶ **Posterior:** Probabilité de l'hypothèse étant donné l'évidence $p(H | E) = \frac{8}{8+20} \approx 28.57\%$ (ce que l'on cherche).

THÉORÈME DE BAYES

- ▶ **Hypothèse H :** Steve est libraire.
- ▶ **Évidence E :** Steve est d'un tempérament doux, timide, ...
- ▶ **Prior:** Probabilité de l'hypothèse avant de recevoir une évidence: $p(H) = \frac{10}{210} = \frac{1}{21} \approx 4.76\%$
- ▶ **Likelihood:** Probabilité de l'évidence étant donné que l'hypothèse est vraie $p(E | H) = 80\%$.
- ▶ **(Likelihood bis):** Probabilité de l'évidence étant donné que l'hypothèse est fausse $p(E | \neg H) = 10\%$.
- ▶ **Posterior:** Probabilité de l'hypothèse étant donné l'évidence $p(H | E) = \frac{8}{8+20} \approx 28.57\%$ (ce que l'on cherche).

THÉORÈME DE BAYES

- ▶ **Hypothèse H :** Steve est libraire.
- ▶ **Évidence E :** Steve est d'un tempérament doux, timide, ...
- ▶ **Prior:** Probabilité de l'hypothèse avant de recevoir une évidence: $p(H) = \frac{10}{210} = \frac{1}{21} \approx 4.76\%$
- ▶ **Likelihood:** Probabilité de l'évidence étant donné que l'hypothèse est vraie $p(E | H) = 80\%$.
- ▶ (Likelihood bis): Probabilité de l'évidence étant donné que l'hypothèse est fausse $p(E | \neg H) = 10\%$.
- ▶ **Posterior:** Probabilité de l'hypothèse étant donné l'évidence $p(H | E) = \frac{8}{8+20} \approx 28.57\%$ (ce que l'on cherche).

THÉORÈME DE BAYES

- ▶ **Hypothèse H :** Steve est libraire.
- ▶ **Évidence E :** Steve est d'un tempérament doux, timide, ...
- ▶ **Prior:** Probabilité de l'hypothèse avant de recevoir une évidence: $p(H) = \frac{10}{210} = \frac{1}{21} \approx 4.76\%$
- ▶ **Likelihood:** Probabilité de l'évidence étant donné que l'hypothèse est vraie $p(E | H) = 80\%$.
- ▶ **(Likelihood bis):** Probabilité de l'évidence étant donné que l'hypothèse est fausse $p(E | \neg H) = 10\%$.
- ▶ **Posterior:** Probabilité de l'hypothèse étant donné l'évidence $p(H | E) = \frac{8}{8+20} \approx 28.57\%$ (ce que l'on cherche).

THÉORÈME DE BAYES

- ▶ **Hypothèse H :** Steve est libraire.
- ▶ **Évidence E :** Steve est d'un tempérament doux, timide, ...
- ▶ **Prior:** Probabilité de l'hypothèse avant de recevoir une évidence: $p(H) = \frac{10}{210} = \frac{1}{21} \approx 4.76\%$
- ▶ **Likelihood:** Probabilité de l'évidence étant donné que l'hypothèse est vraie $p(E | H) = 80\%$.
- ▶ **(Likelihood bis):** Probabilité de l'évidence étant donné que l'hypothèse est fausse $p(E | \neg H) = 10\%$.
- ▶ **Posterior:** Probabilité de l'hypothèse étant donné l'évidence $p(H | E) = \frac{8}{8+20} \approx 28.57\%$ (ce que l'on cherche).

THÉORÈME DE BAYES

- ▶ **Prior:** Probabilité de l'hypothèse avant de recevoir une évidence: $p(H) = \frac{10}{210} = \frac{1}{21} \approx 4.76\%$
- ▶ **Posterior:** Probabilité de l'hypothèse étant donné l'évidence $p(H | E) = \frac{8}{8+20} \approx 28.57\%$ (ce que l'on cherche).
- ▶ Notre croyance que Steve est libraire est passée de 4.76% (croyance a priori) à 28.57% (croyance a posteriori).
- ▶ Intuitivement, on se serait attendu à une probabilité a posteriori plus élevée...
- ▶ La différence entre le *prior* et le *posterior* est appelée **belief updating** ou **belief revision** (révision des croyances).

THÉORÈME DE BAYES

- ▶ **Prior:** Probabilité de l'hypothèse avant de recevoir une évidence: $p(H) = \frac{10}{210} = \frac{1}{21} \approx 4.76\%$
- ▶ **Posterior:** Probabilité de l'hypothèse étant donné l'évidence $p(H | E) = \frac{8}{8+20} \approx 28.57\%$ (ce que l'on cherche).
- ▶ Notre croyance que Steve est libraire est passée de 4.76% (croyance a priori) à 28.57% (croyance a posteriori).
- ▶ Intuitivement, on se serait attendu à une probabilité a posteriori plus élevée...
- ▶ La différence entre le *prior* et le *posterior* est appelée **belief updating** ou **belief revision** (révision des croyances).

THÉORÈME DE BAYES

- ▶ **Prior:** Probabilité de l'hypothèse avant de recevoir une évidence: $p(H) = \frac{10}{210} = \frac{1}{21} \approx 4.76\%$
- ▶ **Posterior:** Probabilité de l'hypothèse étant donné l'évidence $p(H | E) = \frac{8}{8+20} \approx 28.57\%$ (ce que l'on cherche).
- ▶ Notre croyance que Steve est libraire est passée de 4.76% (croyance a priori) à 28.57% (croyance a posteriori).
- ▶ Intuitivement, on se serait attendu à une probabilité a posteriori plus élevée...
- ▶ La différence entre le *prior* et le *posterior* est appelée **belief updating** ou **belief revision** (révision des croyances).

THÉORÈME DE BAYES

- ▶ **Prior:** Probabilité de l'hypothèse avant de recevoir une évidence: $p(H) = \frac{10}{210} = \frac{1}{21} \approx 4.76\%$
- ▶ **Posterior:** Probabilité de l'hypothèse étant donné l'évidence $p(H | E) = \frac{8}{8+20} \approx 28.57\%$ (ce que l'on cherche).
- ▶ Notre croyance que Steve est libraire est passée de 4.76% (croyance a priori) à 28.57% (croyance a posteriori).
- ▶ Intuitivement, on se serait attendu à une probabilité a posteriori plus élevée...
- ▶ La différence entre le *prior* et le *posterior* est appelée **belief updating** ou **belief revision** (révision des croyances).

THÉORÈME DE BAYES

- ▶ **Prior:** Probabilité de l'hypothèse avant de recevoir une évidence: $p(H) = \frac{10}{210} = \frac{1}{21} \approx 4.76\%$
- ▶ **Posterior:** Probabilité de l'hypothèse étant donné l'évidence $p(H | E) = \frac{8}{8+20} \approx 28.57\%$ (ce que l'on cherche).
- ▶ Notre croyance que Steve est libraire est passée de 4.76% (croyance a priori) à 28.57% (croyance a posteriori).
- ▶ Intuitivement, on se serait attendu à une probabilité a posteriori plus élevée...
- ▶ La différence entre le *prior* et le *posterior* est appelée **belief updating** ou **belief revision** (révision des croyances).

THÉORÈME DE BAYES

- Grâce au **théorème de Bayes**, on peut calculer la probabilité conditionnelle $p(H \mid E)$ à partir de son *inverse* $p(E \mid H)$:

$$p(H \mid E) \stackrel{\text{(Bayes)}}{=} \frac{p(H) p(E \mid H)}{p(E)}$$

$$\text{(prob. totale)} = \frac{p(H) p(E \mid H)}{p(E \cap H) + p(E \cap \neg H)}$$

$$\text{(prob. cond.)} = \frac{p(H) p(E \mid H)}{p(H) p(E \mid H) + p(\neg H) p(E \mid \neg H)}$$

$$= \frac{\frac{10}{210} \frac{80}{100}}{\frac{10}{210} \frac{80}{100} + \frac{200}{210} \frac{10}{100}}$$

$$= \frac{8}{8 + 20}$$

THÉORÈME DE BAYES

- Grâce au **théorème de Bayes**, on peut calculer la probabilité conditionnelle $p(H \mid E)$ à partir de son *inverse* $p(E \mid H)$:

$$p(H \mid E) \stackrel{\text{(Bayes)}}{=} \frac{p(H) p(E \mid H)}{p(E)}$$

$$\text{(prob. totale)} = \frac{p(H) p(E \mid H)}{p(E \cap H) + p(E \cap \neg H)}$$

$$\text{(prob. cond.)} = \frac{p(H) p(E \mid H)}{p(H) p(E \mid H) + p(\neg H) p(E \mid \neg H)}$$

$$= \frac{\frac{10}{210} \frac{80}{100}}{\frac{10}{210} \frac{80}{100} + \frac{200}{210} \frac{10}{100}}$$

$$= \frac{8}{8 + 20}$$

THÉORÈME DE BAYES

- Grâce au **théorème de Bayes**, on peut calculer la probabilité conditionnelle $p(H \mid E)$ à partir de son *inverse* $p(E \mid H)$:

$$\begin{aligned} p(H \mid E) &\stackrel{\text{(Bayes)}}{=} \frac{p(H) p(E \mid H)}{p(E)} \\ \text{(prob. totale)} &= \frac{p(H) p(E \mid H)}{p(E \cap H) + p(E \cap \neg H)} \\ \text{(prob. cond.)} &= \frac{p(H) p(E \mid H)}{p(H) p(E \mid H) + p(\neg H) p(E \mid \neg H)} \\ &= \frac{\frac{10}{210} \frac{80}{100}}{\frac{10}{210} \frac{80}{100} + \frac{200}{210} \frac{10}{100}} \\ &= \frac{8}{8 + 20} \end{aligned}$$

THÉORÈME DE BAYES

- Grâce au **théorème de Bayes**, on peut calculer la probabilité conditionnelle $p(H \mid E)$ à partir de son *inverse* $p(E \mid H)$:

$$\begin{aligned}
 p(H \mid E) &\stackrel{\text{(Bayes)}}{=} \frac{p(H) p(E \mid H)}{p(E)} \\
 (\text{prob. totale}) &= \frac{p(H) p(E \mid H)}{p(E \cap H) + p(E \cap \neg H)} \\
 (\text{prob. cond.}) &= \frac{p(H) p(E \mid H)}{p(H) p(E \mid H) + p(\neg H) p(E \mid \neg H)} \\
 &= \frac{\frac{10}{210} \frac{80}{100}}{\frac{10}{210} \frac{80}{100} + \frac{200}{210} \frac{10}{100}} \\
 &= \frac{8}{8 + 20}
 \end{aligned}$$

THÉORÈME DE BAYES

- Grâce au **théorème de Bayes**, on peut calculer la probabilité conditionnelle $p(H \mid E)$ à partir de son *inverse* $p(E \mid H)$:

$$\begin{aligned} p(H \mid E) &\stackrel{\text{(Bayes)}}{=} \frac{p(H) p(E \mid H)}{p(E)} \\ (\text{prob. totale}) &= \frac{p(H) p(E \mid H)}{p(E \cap H) + p(E \cap \neg H)} \\ (\text{prob. cond.}) &= \frac{p(H) p(E \mid H)}{p(H) p(E \mid H) + p(\neg H) p(E \mid \neg H)} \\ &= \frac{\frac{10}{210} \frac{80}{100}}{\frac{10}{210} \frac{80}{100} + \frac{200}{210} \frac{10}{100}} \\ &= \frac{8}{8 + 20} \end{aligned}$$

THÉORÈME DE BAYES

- Grâce au **théorème de Bayes**, on peut calculer la probabilité conditionnelle $p(H \mid E)$ à partir de son *inverse* $p(E \mid H)$:

$$\begin{aligned} p(H \mid E) &\stackrel{\text{(Bayes)}}{=} \frac{p(H) p(E \mid H)}{p(E)} \\ (\text{prob. totale}) &= \frac{p(H) p(E \mid H)}{p(E \cap H) + p(E \cap \neg H)} \\ (\text{prob. cond.}) &= \frac{p(H) p(E \mid H)}{p(H) p(E \mid H) + p(\neg H) p(E \mid \neg H)} \\ &= \frac{\frac{10}{210} \frac{80}{100}}{\frac{10}{210} \frac{80}{100} + \frac{200}{210} \frac{10}{100}} \\ &= \frac{8}{8 + 20} \end{aligned}$$

THÉORÈME DE BAYES

- Grâce au **théorème de Bayes**, on peut calculer la probabilité conditionnelle $p(H \mid E)$ à partir de son *inverse* $p(E \mid H)$:

$$\begin{aligned}
 p(H \mid E) &\stackrel{\text{(Bayes)}}{=} \frac{p(H) p(E \mid H)}{p(E)} \\
 (\text{prob. totale}) &= \frac{p(H) p(E \mid H)}{p(E \cap H) + p(E \cap \neg H)} \\
 (\text{prob. cond.}) &= \frac{p(H) p(E \mid H)}{p(H) p(E \mid H) + p(\neg H) p(E \mid \neg H)} \\
 &= \frac{\frac{10}{210} \frac{80}{100}}{\frac{10}{210} \frac{80}{100} + \frac{200}{210} \frac{10}{100}} \\
 &= \frac{8}{8 + 20}
 \end{aligned}$$

PARADOXE DU TEST DE DÉPISTAGE

- ▶ Une maladie *rare* possède un taux de personnes infectées de 0.01% (1 personne malade sur 10'000).
- ▶ Un test de dépistage possède les caractéristiques suivantes:
 - (A) Si une personne est malade, le test est positif à 99%
→ vrai positif
 - (B) Si une personne n'est pas malade, le test est positif à 0,1%
→ faux positif.
- ▶ Remarque: le test à l'air d'excellente qualité!
- ▶ *Quelle est la probabilité que la personne soit malade si le test est positif?*

PARADOXE DU TEST DE DÉPISTAGE

- ▶ Une maladie *rare* possède un taux de personnes infectées de 0.01% (1 personne malade sur 10'000).
- ▶ Un test de dépistage possède les caractéristiques suivantes:
 - (A) Si une personne est malade, le test est positif à 99%
→ vrai positif
 - (B) Si une personne n'est pas malade, le test est positif à 0,1%
→ faux positif.
- ▶ Remarque: le test à l'air d'excellente qualité!
- ▶ *Quelle est la probabilité que la personne soit malade si le test est positif?*

PARADOXE DU TEST DE DÉPISTAGE

- ▶ Une maladie *rare* possède un taux de personnes infectées de 0.01% (1 personne malade sur 10'000).
- ▶ Un test de dépistage possède les caractéristiques suivantes:
 - (A) Si une personne est malade, le test est positif à 99%
→ vrai positif
 - (B) Si une personne n'est pas malade, le test est positif à 0,1%
→ faux positif.
- ▶ Remarque: le test à l'air d'excellente qualité!
- ▶ *Quelle est la probabilité que la personne soit malade si le test est positif?*

PARADOXE DU TEST DE DÉPISTAGE

- ▶ Une maladie *rare* possède un taux de personnes infectées de 0.01% (1 personne malade sur 10'000).
- ▶ Un test de dépistage possède les caractéristiques suivantes:
 - (A) Si une personne est malade, le test est positif à 99%
→ vrai positif
 - (B) Si une personne n'est pas malade, le test est positif à 0,1%
→ faux positif.
- ▶ Remarque: le test à l'air d'excellente qualité!
- ▶ *Quelle est la probabilité que la personne soit malade si le test est positif?*

PARADOXE DU TEST DE DÉPISTAGE

- ▶ Une maladie *rare* possède un taux de personnes infectées de 0.01% (1 personne malade sur 10'000).
- ▶ Un test de dépistage possède les caractéristiques suivantes:
 - (A) Si une personne est malade, le test est positif à 99%
→ vrai positif
 - (B) Si une personne n'est pas malade, le test est positif à 0,1%
→ faux positif.
- ▶ **Remarque:** le test à l'air d'excellente qualité!
- ▶ *Quelle est la probabilité que la personne soit malade si le test est positif?*

PARADOXE DU TEST DE DÉPISTAGE

- ▶ Une maladie *rare* possède un taux de personnes infectées de 0.01% (1 personne malade sur 10'000).
- ▶ Un test de dépistage possède les caractéristiques suivantes:
 - (A) Si une personne est malade, le test est positif à 99%
→ vrai positif
 - (B) Si une personne n'est pas malade, le test est positif à 0,1%
→ faux positif.
- ▶ **Remarque:** le test à l'air d'excellente qualité!
- ▶ *Quelle est la probabilité que la personne soit malade si le test est positif?*

PARADOXE DU TEST DE DÉPISTAGE

- ▶ On note M l'évènement: "*la personne est malade*" et $\bar{M}$ "*la personne n'est pas malade*".
- ▶ On note $+$ l'évènement "*le test est positif*".
- ▶ On cherche la probabilité conditionnelle $p(M \mid +)$.
- ▶ On a les données suivantes (épidémiologiques, statistiques):

$$p(M) = 0.01\% = 0.0001 \quad \text{donc} \quad p(\bar{M}) = 0.9999$$

$$p(+ \mid M) = 99\% = 0.99$$

$$p(+ \mid \bar{M}) = 0.1\% = 0.001$$

PARADOXE DU TEST DE DÉPISTAGE

- ▶ On note M l'évènement: "*la personne est malade*" et $\bar{M}$ "*la personne n'est pas malade*".
- ▶ On note $+$ l'évènement "*le test est positif*".
- ▶ On cherche la probabilité conditionnelle $p(M \mid +)$.
- ▶ On a les données suivantes (épidémiologiques, statistiques):

$$p(M) = 0.01\% = 0.0001 \quad \text{donc} \quad p(\bar{M}) = 0.9999$$

$$p(+ \mid M) = 99\% = 0.99$$

$$p(+ \mid \bar{M}) = 0.1\% = 0.001$$

PARADOXE DU TEST DE DÉPISTAGE

- ▶ On note M l'évènement: "*la personne est malade*" et $\bar{M}$ "*la personne n'est pas malade*".
- ▶ On note $+$ l'évènement "*le test est positif*".
- ▶ On cherche la probabilité conditionnelle $p(M \mid +)$.
- ▶ On a les données suivantes (épidémiologiques, statistiques):

$$p(M) = 0.01\% = 0.0001 \quad \text{donc} \quad p(\bar{M}) = 0.9999$$

$$p(+ \mid M) = 99\% = 0.99$$

$$p(+ \mid \bar{M}) = 0.1\% = 0.001$$

PARADOXE DU TEST DE DÉPISTAGE

- ▶ On note M l'évènement: "*la personne est malade*" et $\bar{M}$ "*la personne n'est pas malade*".
- ▶ On note $+$ l'évènement "*le test est positif*".
- ▶ On cherche la probabilité conditionnelle $p(M \mid +)$.
- ▶ On a les données suivantes (épidémiologiques, statistiques):

$$p(M) = 0.01\% = 0.0001 \quad \text{donc} \quad p(\bar{M}) = 0.9999$$

$$p(+ \mid M) = 99\% = 0.99$$

$$p(+ \mid \bar{M}) = 0.1\% = 0.001$$

PARADOXE DU TEST DE DÉPISTAGE

- ▶ On note M l'évènement: "*la personne est malade*" et $\bar{M}$ "*la personne n'est pas malade*".
- ▶ On note $+$ l'évènement "*le test est positif*".
- ▶ On cherche la probabilité conditionnelle $p(M \mid +)$.
- ▶ On a les données suivantes (épidémiologiques, statistiques):

$$p(M) = 0.01\% = 0.0001 \quad \text{donc} \quad p(\bar{M}) = 0.9999$$

$$p(+ \mid M) = 99\% = 0.99$$

$$p(+ \mid \bar{M}) = 0.1\% = 0.001$$

PARADOXE DU TEST DE DÉPISTAGE

- ▶ On note M l'évènement: "*la personne est malade*" et $\bar{M}$ "*la personne n'est pas malade*".
- ▶ On note $+$ l'évènement "*le test est positif*".
- ▶ On cherche la probabilité conditionnelle $p(M \mid +)$.
- ▶ On a les données suivantes (épidémiologiques, statistiques):

$$p(M) = 0.01\% = 0.0001 \quad \text{donc} \quad p(\bar{M}) = 0.9999$$

$$p(+ \mid M) = 99\% = 0.99$$

$$p(+ \mid \bar{M}) = 0.1\% = 0.001$$

PARADOXE DU TEST DE DÉPISTAGE

- ▶ On note M l'évènement: "*la personne est malade*" et $\bar{M}$ "*la personne n'est pas malade*".
- ▶ On note $+$ l'évènement "*le test est positif*".
- ▶ On cherche la probabilité conditionnelle $p(M \mid +)$.
- ▶ On a les données suivantes (épidémiologiques, statistiques):

$$p(M) = 0.01\% = 0.0001 \quad \text{donc} \quad p(\bar{M}) = 0.9999$$

$$p(+ \mid M) = 99\% = 0.99$$

$$p(+ \mid \bar{M}) = 0.1\% = 0.001$$

PARADOXE DU TEST DE DÉPISTAGE

- ▶ On connaît la probabilité conditionnelle $p(+ | M) = 0.99$.
- ▶ On cherche la probabilité conditionnelle *inverse* $p(M | +)$.
- ▶ Cas typique d'utilisation du **théorème de Bayes**.

$$p(M | +) \stackrel{\text{(Bayes)}}{=} \frac{p(+ | M) p(M)}{p(+)}$$

PARADOXE DU TEST DE DÉPISTAGE

- ▶ On connaît la probabilité conditionnelle $p(+ | M) = 0.99$.
- ▶ On cherche la probabilité conditionnelle *inverse* $p(M | +)$.
- ▶ Cas typique d'utilisation du **théorème de Bayes**.

$$p(M | +) \stackrel{\text{(Bayes)}}{=} \frac{p(+ | M) p(M)}{p(+)}$$

PARADOXE DU TEST DE DÉPISTAGE

- ▶ On connaît la probabilité conditionnelle $p(+ | M) = 0.99$.
- ▶ On cherche la probabilité conditionnelle *inverse* $p(M | +)$.
- ▶ Cas typique d'utilisation du **théorème de Bayes**.

$$\begin{aligned} p(M | +) &\stackrel{\text{(Bayes)}}{=} \frac{p(+ | M) p(M)}{p(+)} \\ \text{(prob. totale)} &= \frac{p(+ | M) p(M)}{p(+ \cap M) + p(+ \cap \bar{M})} \\ \text{(prob. cond.)} &= \frac{p(+ | M) p(M)}{p(+ | M) p(M) + p(+ | \bar{M}) p(\bar{M})} \\ &= \frac{0.99 \cdot 0.0001}{0.99 \cdot 0.0001 + 0.001 \cdot 0.9999} \simeq 0.09 = 9\% \end{aligned}$$

PARADOXE DU TEST DE DÉPISTAGE

- ▶ On connaît la probabilité conditionnelle $p(+ | M) = 0.99$.
- ▶ On cherche la probabilité conditionnelle *inverse* $p(M | +)$.
- ▶ Cas typique d'utilisation du **théorème de Bayes**.

$$\begin{aligned} p(M | +) &\stackrel{\text{(Bayes)}}{=} \frac{p(+ | M) p(M)}{p(+)} \\ \text{(prob. totale)} &= \frac{p(+ | M) p(M)}{p(+ \cap M) + p(+ \cap \bar{M})} \\ \text{(prob. cond.)} &= \frac{p(+ | M) p(M)}{p(+ | M) p(M) + p(+ | \bar{M}) p(\bar{M})} \\ &= \frac{0.99 \cdot 0.0001}{0.99 \cdot 0.0001 + 0.001 \cdot 0.9999} \simeq 0.09 = 9\% \end{aligned}$$

PARADOXE DU TEST DE DÉPISTAGE

- ▶ On connaît la probabilité conditionnelle $p(+ | M) = 0.99$.
- ▶ On cherche la probabilité conditionnelle *inverse* $p(M | +)$.
- ▶ Cas typique d'utilisation du **théorème de Bayes**.

$$\begin{aligned} p(M | +) &\stackrel{\text{(Bayes)}}{=} \frac{p(+ | M) p(M)}{p(+)} \\ \text{(prob. totale)} &= \frac{p(+ | M) p(M)}{p(+ \cap M) + p(+ \cap \bar{M})} \\ \text{(prob. cond.)} &= \frac{p(+ | M) p(M)}{p(+ | M) p(M) + p(+ | \bar{M}) p(\bar{M})} \\ &= \frac{0.99 \cdot 0.0001}{0.99 \cdot 0.0001 + 0.001 \cdot 0.9999} \simeq 0.09 = 9\% \end{aligned}$$

PARADOXE DU TEST DE DÉPISTAGE

- ▶ On connaît la probabilité conditionnelle $p(+ | M) = 0.99$.
- ▶ On cherche la probabilité conditionnelle *inverse* $p(M | +)$.
- ▶ Cas typique d'utilisation du **théorème de Bayes**.

$$\begin{aligned} p(M | +) &\stackrel{\text{(Bayes)}}{=} \frac{p(+ | M) p(M)}{p(+)} \\ \text{(prob. totale)} &= \frac{p(+ | M) p(M)}{p(+ \cap M) + p(+ \cap \bar{M})} \\ \text{(prob. cond.)} &= \frac{p(+ | M) p(M)}{p(+ | M) p(M) + p(+ | \bar{M}) p(\bar{M})} \\ &= \frac{0.99 \cdot 0.0001}{0.99 \cdot 0.0001 + 0.001 \cdot 0.9999} \simeq 0.09 = 9\% \end{aligned}$$

PARADOXE DU TEST DE DÉPISTAGE

- ▶ On connaît la probabilité conditionnelle $p(+ | M) = 0.99$.
- ▶ On cherche la probabilité conditionnelle *inverse* $p(M | +)$.
- ▶ Cas typique d'utilisation du **théorème de Bayes**.

$$\begin{aligned} p(M | +) &\stackrel{\text{(Bayes)}}{=} \frac{p(+ | M) p(M)}{p(+)} \\ \text{(prob. totale)} &= \frac{p(+ | M) p(M)}{p(+ \cap M) + p(+ \cap \bar{M})} \\ \text{(prob. cond.)} &= \frac{p(+ | M) p(M)}{p(+ | M) p(M) + p(+ | \bar{M}) p(\bar{M})} \\ &= \frac{0.99 \cdot 0.0001}{0.99 \cdot 0.0001 + 0.001 \cdot 0.9999} \simeq 0.09 = 9\% \end{aligned}$$

▶ C'est très bas! On pensait que le test était excellent! Ce paradoxe provient de la rareté de la maladie...

PARADOXE DU TEST DE DÉPISTAGE

- ▶ On connaît la probabilité conditionnelle $p(+ | M) = 0.99$.
- ▶ On cherche la probabilité conditionnelle *inverse* $p(M | +)$.
- ▶ Cas typique d'utilisation du **théorème de Bayes**.

$$\begin{aligned} p(M | +) &\stackrel{\text{(Bayes)}}{=} \frac{p(+ | M) p(M)}{p(+)} \\ \text{(prob. totale)} &= \frac{p(+ | M) p(M)}{p(+ \cap M) + p(+ \cap \bar{M})} \\ \text{(prob. cond.)} &= \frac{p(+ | M) p(M)}{p(+ | M) p(M) + p(+ | \bar{M}) p(\bar{M})} \\ &= \frac{0.99 \cdot 0.0001}{0.99 \cdot 0.0001 + 0.001 \cdot 0.9999} \simeq 0.09 = 9\% \end{aligned}$$

▶ C'est très bas! On pensait que le test était excellent! Ce paradoxe provient de la rareté de la maladie...

PARADOXE DU TEST DE DÉPISTAGE

- ▶ On connaît la probabilité conditionnelle $p(+ | M) = 0.99$.
- ▶ On cherche la probabilité conditionnelle *inverse* $p(M | +)$.
- ▶ Cas typique d'utilisation du **théorème de Bayes**.

$$\begin{aligned} p(M | +) &\stackrel{\text{(Bayes)}}{=} \frac{p(+ | M) p(M)}{p(+)} \\ \text{(prob. totale)} &= \frac{p(+ | M) p(M)}{p(+ \cap M) + p(+ \cap \bar{M})} \\ \text{(prob. cond.)} &= \frac{p(+ | M) p(M)}{p(+ | M) p(M) + p(+ | \bar{M}) p(\bar{M})} \\ &= \frac{0.99 \cdot 0.0001}{0.99 \cdot 0.0001 + 0.001 \cdot 0.9999} \simeq 0.09 = 9\% \end{aligned}$$

- ▶ **C'est très bas! On pensait que le test était excellent! Ce paradoxe provient de la rareté de la maladie...**

MODÈLE PROBABILISTE

- Soient $\mathbf{X} = (X_1, \dots, X_P)$ des variables explicatives et Y une variable réponse qualitative à valeurs dans $C = \{c_1, \dots, c_K\}$.
- Soit un train set

$$S = \{(x_i, y_i) \in \mathbb{R}^P \times C : i = 1, \dots, N\}.$$

MODÈLE PROBABILISTE

- Soient $\mathbf{X} = (X_1, \dots, X_P)$ des variables explicatives et Y une variable réponse qualitative à valeurs dans $C = \{c_1, \dots, c_K\}$.
- Soit un train set

$$S = \{(\mathbf{x}_i, y_i) \in \mathbb{R}^P \times C : i = 1, \dots, N\}.$$

MODÈLE PROBABILISTE

- Le **modèle probabiliste** pour un classifieur consiste à calculer la probabilité conditionnelle, étant donné un point x , d'appartenir à chacune des classes c_k , i.e.

$$p(Y = c_k \mid \mathbf{X} = \mathbf{x}) \text{ pour tout } k = 1, \dots, K$$

- Ensuite, on associe x à la classe $\hat{c}$ dont la probabilité conditionnelle est maximale, i.e.,

$$\hat{c} = \arg \max_{c_k \in C} p(Y = c_k \mid \mathbf{X} = \mathbf{x})$$

MODÈLE PROBABILISTE

- Le **modèle probabiliste** pour un classifieur consiste à calculer la probabilité conditionnelle, étant donné un point $\mathbf{x}$, d'appartenir à chacune des classes c_k , i.e.

$$p(Y = c_k \mid \mathbf{X} = \mathbf{x}) \text{ pour tout } k = 1, \dots, K$$

- Ensuite, on associe $\mathbf{x}$ à la classe $\hat{c}$ dont la probabilité conditionnelle est maximale, i.e.,

$$\hat{c} = \arg \max_{c_k \in C} p(Y = c_k \mid \mathbf{X} = \mathbf{x})$$

MODÈLE PROBABILISTE

- Pour un point $\mathbf{x}$ on abrège $p(Y = c_k \mid \mathbf{X} = \mathbf{x})$ par $p(c_k \mid \mathbf{x})$.
- Une application répétée de la règles des probabilités conditionnelles donne:

$$p(c_k, x_1, \dots, x_P) = p(x_1, \dots, x_P, c_k)$$

$$= p(x_1 \mid x_2, \dots, x_P, c_k) p(x_2, \dots, x_P \mid c_k)$$

$$= p(x_1 \mid c_k) p(x_2, \dots, x_P \mid c_k)$$

$$= p(x_1 \mid c_k) p(x_2 \mid c_k) \dots p(x_P \mid c_k)$$

$$= p(c_k) p(x_1 \mid c_k) p(x_2 \mid c_k) \dots p(x_P \mid c_k)$$

$$= p(c_k) p(x_1, \dots, x_P \mid c_k)$$

$$= p(c_k) p(\mathbf{x} \mid c_k)$$

$$= p(c_k) \prod_{p=1}^P p(x_p \mid c_k)$$

$$= p(c_k) \prod_{p=1}^P \frac{1}{N_k} \sum_{i \in I_k} \mathbb{1}_{\{x_p = x_{pi}\}}$$

MODÈLE PROBABILISTE

- Pour un point $\mathbf{x}$ on abrège $p(Y = c_k \mid \mathbf{X} = \mathbf{x})$ par $p(c_k \mid \mathbf{x})$.
- Une application répétée de la règles des probabilités conditionnelles donne:

$$\begin{aligned} p(c_k, x_1, \dots, x_P) &= p(x_1, \dots, x_P, c_k) \\ &= p(x_1 \mid x_2, \dots, x_P, c_k) p(x_2, \dots, x_P, c_k) \\ &= p(x_1 \mid x_2, \dots, x_P, c_k) \\ &\quad p(x_2 \mid x_3, \dots, x_P, c_k) p(x_3, \dots, x_P, c_k) \\ &= \dots \\ &= p(x_1 \mid x_2, \dots, x_P, c_k) \\ &\quad p(x_2 \mid x_3, \dots, x_P, c_k) \\ &\quad \dots \\ &\quad p(x_{P-1} \mid x_P, c_k) p(x_P \mid c_k) p(c_k) \end{aligned}$$

MODÈLE PROBABILISTE

- Pour un point $\mathbf{x}$ on abrège $p(Y = c_k \mid \mathbf{X} = \mathbf{x})$ par $p(c_k \mid \mathbf{x})$.
- Une application répétée de la règles des probabilités conditionnelles donne:

$$\begin{aligned} p(c_k, x_1, \dots, x_P) &= p(x_1, \dots, x_P, c_k) \\ &= p(x_1 \mid x_2, \dots, x_P, c_k) p(x_2, \dots, x_P, c_k) \\ &= p(x_1 \mid x_2, \dots, x_P, c_k) \\ &\quad p(x_2 \mid x_3, \dots, x_P, c_k) p(x_3, \dots, x_P, c_k) \\ &= \dots \\ &= p(x_1 \mid x_2, \dots, x_P, c_k) \\ &\quad p(x_2 \mid x_3, \dots, x_P, c_k) \\ &\quad \dots \\ &\quad p(x_{P-1} \mid x_P, c_k) p(x_P \mid c_k) p(c_k) \end{aligned}$$

MODÈLE PROBABILISTE

- Pour un point $\mathbf{x}$ on abrège $p(Y = c_k \mid \mathbf{X} = \mathbf{x})$ par $p(c_k \mid \mathbf{x})$.
- Une application répétée de la règles des probabilités conditionnelles donne:

$$\begin{aligned} p(c_k, x_1, \dots, x_P) &= p(x_1, \dots, x_P, c_k) \\ &= p(x_1 \mid x_2, \dots, x_P, c_k) p(x_2, \dots, x_P, c_k) \\ &= p(x_1 \mid x_2, \dots, x_P, c_k) \\ &\quad p(x_2 \mid x_3, \dots, x_P, c_k) p(x_3, \dots, x_P, c_k) \\ &= \dots \\ &= p(x_1 \mid x_2, \dots, x_P, c_k) \\ &\quad p(x_2 \mid x_3, \dots, x_P, c_k) \\ &\quad \dots \\ &\quad p(x_{P-1} \mid x_P, c_k) p(x_P \mid c_k) p(c_k) \end{aligned}$$

MODÈLE PROBABILISTE

- Pour un point $\mathbf{x}$ on abrège $p(Y = c_k \mid \mathbf{X} = \mathbf{x})$ par $p(c_k \mid \mathbf{x})$.
- Une application répétée de la règles des probabilités conditionnelles donne:

$$\begin{aligned} p(c_k, x_1, \dots, x_P) &= p(x_1, \dots, x_P, c_k) \\ &= p(x_1 \mid x_2, \dots, x_P, c_k) p(x_2, \dots, x_P, c_k) \\ &= p(x_1 \mid x_2, \dots, x_P, c_k) \\ &\quad p(x_2 \mid x_3, \dots, x_P, c_k) p(x_3, \dots, x_P, c_k) \\ &= \dots \\ &= p(x_1 \mid x_2, \dots, x_P, c_k) \\ &\quad p(x_2 \mid x_3, \dots, x_P, c_k) \\ &\quad \dots \\ &\quad p(x_{P-1} \mid x_P, c_k) p(x_P \mid c_k) p(c_k) \end{aligned}$$

MODÈLE PROBABILISTE

- Pour un point $\mathbf{x}$ on abrège $p(Y = c_k \mid \mathbf{X} = \mathbf{x})$ par $p(c_k \mid \mathbf{x})$.
- Une application répétée de la règles des probabilités conditionnelles donne:

$$\begin{aligned} p(c_k, x_1, \dots, x_P) &= p(x_1, \dots, x_P, c_k) \\ &= p(x_1 \mid x_2, \dots, x_P, c_k) p(x_2, \dots, x_P, c_k) \\ &= p(x_1 \mid x_2, \dots, x_P, c_k) \\ &\quad p(x_2 \mid x_3, \dots, x_P, c_k) p(x_3, \dots, x_P, c_k) \\ &= \dots \\ &= p(x_1 \mid x_2, \dots, x_P, c_k) \\ &\quad p(x_2 \mid x_3, \dots, x_P, c_k) \\ &\quad \dots \\ &\quad p(x_{P-1} \mid x_P, c_k) p(x_P \mid c_k) p(c_k) \end{aligned}$$

MODÈLE PROBABILISTE

- Pour un point $\mathbf{x}$ on abrège $p(Y = c_k \mid \mathbf{X} = \mathbf{x})$ par $p(c_k \mid \mathbf{x})$.
- Une application répétée de la règles des probabilités conditionnelles donne:

$$\begin{aligned} p(c_k, x_1, \dots, x_P) &= p(x_1, \dots, x_P, c_k) \\ &= p(x_1 \mid x_2, \dots, x_P, c_k) p(x_2, \dots, x_P, c_k) \\ &= p(x_1 \mid x_2, \dots, x_P, c_k) \\ &\quad p(x_2 \mid x_3, \dots, x_P, c_k) p(x_3, \dots, x_P, c_k) \\ &= \dots \\ &= p(x_1 \mid x_2, \dots, x_P, c_k) \\ &\quad p(x_2 \mid x_3, \dots, x_P, c_k) \\ &\quad \dots \\ &\quad p(x_{P-1} \mid x_P, c_k) p(x_P \mid c_k) p(c_k) \end{aligned}$$

HYPOTHÈSE NAÏVE

- ▶ On introduit l'hypothèse naïve d'*indépendance conditionnelle*: chaque X_i est indépendant des autres caractéristiques X_j , conditionnellement à Y , i.e.

$$p(x_j \mid x_{j+1}, \dots, x_P, c_k) = p(x_j \mid c_k)$$

- ▶ **Exemple:** Classification de fruits à partir de divers attributs (couleur, forme, etc.). L'hypothèse naïve dit:

$$\begin{aligned} p(X_1 = \text{rouge} \mid X_2 = \text{rond}, Y = \text{pomme}) \\ = p(X_1 = \text{rouge} \mid Y = \text{pomme}) \end{aligned}$$

HYPOTHÈSE NAÏVE

- ▶ On introduit l'hypothèse naïve d'*indépendance conditionnelle*: chaque X_i est indépendant des autres caractéristiques X_j , conditionnellement à Y , i.e.

$$p(x_j \mid x_{j+1}, \dots, x_P, c_k) = p(x_j \mid c_k)$$

- ▶ **Exemple:** Classification de fruits à partir de divers attributs (couleur, forme, etc.). L'hypothèse naïve dit:

$$\begin{aligned} p(X_1 = \text{rouge} \mid X_2 = \text{rond}, Y = \text{pomme}) \\ = p(X_1 = \text{rouge} \mid Y = \text{pomme}) \end{aligned}$$

HYPOTHÈSE NAÏVE

- En appliquant l'hypothèse naïve, on a:

$$p(c_k, x_1, \dots, x_P) = p(x_1 \mid x_2, \dots, x_P, c_k)$$

$$p(x_2 \mid x_3, \dots, x_P, c_k)$$

...

$$p(x_{n-1} \mid x_P, c_k) p(x_P \mid c_k) p(c_k)$$

$$= p(x_1 \mid c_k) p(x_2 \mid c_k) p(x_3 \mid c_k) \cdots p(c_k)$$

$$= p(c_k) \prod_{j=1}^P p(x_j \mid c_k) \quad (1)$$

HYPOTHÈSE NAÏVE

- En appliquant l'hypothèse naïve, on a:

$$p(c_k, x_1, \dots, x_P) = p(x_1 \mid x_2, \dots, x_P, c_k)$$

$$p(x_2 \mid x_3, \dots, x_P, c_k)$$

...

$$p(x_{n-1} \mid x_P, c_k) p(x_P \mid c_k) p(c_k)$$

$$= p(x_1 \mid c_k) p(x_2 \mid c_k) p(x_3 \mid c_k) \cdots p(c_k)$$

$$= p(c_k) \prod_{j=1}^P p(x_j \mid c_k) \quad (1)$$

HYPOTHÈSE NAÏVE

- En appliquant l'hypothèse naïve, on a:

$$p(c_k, x_1, \dots, x_P) = p(x_1 \mid x_2, \dots, x_P, c_k)$$

$$p(x_2 \mid x_3, \dots, x_P, c_k)$$

...

$$p(x_{n-1} \mid x_P, c_k) p(x_P \mid c_k) p(c_k)$$

$$= p(x_1 \mid c_k) p(x_2 \mid c_k) p(x_3 \mid c_k) \cdots p(c_k)$$

$$= p(c_k) \prod_{j=1}^P p(x_j \mid c_k) \quad (1)$$

HYPOTHÈSE NAÏVE

- En appliquant l'hypothèse naïve, on a:

$$\begin{aligned} p(c_k, x_1, \dots, x_P) &= p(x_1 \mid x_2, \dots, x_P, c_k) \\ &\quad p(x_2 \mid x_3, \dots, x_P, c_k) \\ &\quad \dots \\ &\quad p(x_{n-1} \mid x_P, c_k) p(x_P \mid c_k) p(c_k) \\ &= p(x_1 \mid c_k) p(x_2 \mid c_k) p(x_3 \mid c_k) \cdots p(c_k) \\ &= p(c_k) \prod_{j=1}^P p(x_j \mid c_k) \end{aligned} \tag{1}$$

NAIVE BAYES CLASSIFIER

- Par le théorème de Bayes et l'équation (1), on a finalement:

$$p(c_k | x_1, \dots, x_P) = \frac{p(c_k, x_1, \dots, x_P)}{p(x_1, \dots, x_P)} = \frac{p(c_k) \prod_{j=1}^P p(x_j | c_k)}{p(x_1, \dots, x_P)}$$

- En résumé, la formule d'un naive Bayes classifier est:

$$p(c_k | \mathbf{x}) = \frac{1}{p(\mathbf{x})} p(c_k) \prod_{j=1}^P p(x_j | c_k) \propto p(c_k) \prod_{j=1}^P p(x_j | c_k)$$

- Ainsi, la **prédiction** $\hat{c}$ du classifieur est donnée par

$$\hat{c} = \arg \max_{c_k \in C} p(c_k | \mathbf{x}) = \arg \max_{c_k \in C} p(c_k) \prod_{j=1}^P p(x_j | c_k)$$

NAIVE BAYES CLASSIFIER

- ▶ Par le théorème de Bayes et l'équation (1), on a finalement:

$$p(c_k \mid x_1, \dots, x_P) = \frac{p(c_k, x_1, \dots, x_P)}{p(x_1, \dots, x_P)} = \frac{p(c_k) \prod_{j=1}^P p(x_j \mid c_k)}{p(x_1, \dots, x_P)}$$

- ▶ En résumé, la formule d'un **naive Bayes classifieur** est:

$$p(c_k \mid \mathbf{x}) = \frac{1}{p(\mathbf{x})} p(c_k) \prod_{j=1}^P p(x_j \mid c_k) \propto p(c_k) \prod_{j=1}^P p(x_j \mid c_k)$$

- ▶ Ainsi, la **prédiction** $\hat{c}$ du classifieur est donnée par

$$\hat{c} = \arg \max_{c_k \in C} p(c_k \mid \mathbf{x}) = \arg \max_{c_k \in C} p(c_k) \prod_{j=1}^P p(x_j \mid c_k)$$

NAIVE BAYES CLASSIFIER

- ▶ Par le théorème de Bayes et l'équation (1), on a finalement:

$$p(c_k | x_1, \dots, x_P) = \frac{p(c_k, x_1, \dots, x_P)}{p(x_1, \dots, x_P)} = \frac{p(c_k) \prod_{j=1}^P p(x_j | c_k)}{p(x_1, \dots, x_P)}$$

- ▶ En résumé, la formule d'un **naive Bayes classifieur** est:

$$p(c_k | \mathbf{x}) = \frac{1}{p(\mathbf{x})} p(c_k) \prod_{j=1}^P p(x_j | c_k) \propto p(c_k) \prod_{j=1}^P p(x_j | c_k)$$

- ▶ Ainsi, la **prédiction** $\hat{c}$ du classifieur est donnée par

$$\hat{c} = \arg \max_{c_k \in C} p(c_k | \mathbf{x}) = \arg \max_{c_k \in C} p(c_k) \prod_{j=1}^P p(x_j | c_k)$$

ESTIMATION DES PARAMÈTRES

- On a donc:

$$p(c_k | \mathbf{x}) = \frac{1}{p(\mathbf{x})} p(c_k) \prod_{j=1}^P p(x_j | c_k) \propto p(c_k) \prod_{j=1}^P p(x_j | c_k)$$

- Grâce au théorème de Bayes et à notre hypothèse naïve, on a pu exprimer la probabilité conditionnelle $p(c_k | \mathbf{x})$ à partir de $p(c_k)$ et des probabilités conditionnelles “inverses” $p(x_j | c_k)$.
- Mais que valent $p(c_k)$ et $p(x_j | c_k)$? Comment estimer $p(c_k)$ et $p(x_j | c_k)$ à partir des data?

ESTIMATION DES PARAMÈTRES

- On a donc:

$$p(c_k | \mathbf{x}) = \frac{1}{p(\mathbf{x})} p(c_k) \prod_{j=1}^P p(x_j | c_k) \propto p(c_k) \prod_{j=1}^P p(x_j | c_k)$$

- Grâce au théorème de Bayes et à notre hypothèse naïve, on a pu exprimer la probabilité conditionnelle $p(c_k | \mathbf{x})$ à partir de $p(c_k)$ et des probabilités conditionnelles “inverses” $p(x_j | c_k)$.
- Mais que valent $p(c_k)$ et $p(x_j | c_k)$? Comment estimer $p(c_k)$ et $p(x_j | c_k)$ à partir des data?


ESTIMATION DES PARAMÈTRES

- On a donc:

$$p(c_k | \mathbf{x}) = \frac{1}{p(\mathbf{x})} p(c_k) \prod_{j=1}^P p(x_j | c_k) \propto p(c_k) \prod_{j=1}^P p(x_j | c_k)$$

- Grâce au théorème de Bayes et à notre hypothèse naïve, on a pu exprimer la probabilité conditionnelle $p(c_k | \mathbf{x})$ à partir de $p(c_k)$ et des probabilités conditionnelles “inverses” $p(x_j | c_k)$.
- Mais que valent $p(c_k)$ et $p(x_j | c_k)$? Comment estimer $p(c_k)$ et $p(x_j | c_k)$ à partir des data?

ESTIMATION DES PRIORS $p(c_k)$ ET DES PROBABILITÉS CONDITIONNELLES $p(x_j | c_k)$



ESTIMATION DES PRIORS

- ▶ **Estimation des “class priors”**: l'estimation des $p(Y = c_k) = p(c_k)$ pour $k = 1, \dots, K$ à partir des data est simple.
- ▶ Soit on suppose que toutes les K classes $c_1, \dots, c_K$ sont équiprobables, auquel cas on a:

$$p(c_k) = \frac{1}{K} \text{ , pour tout } k = 1, \dots, K.$$

- ▶ Ou alors on estime $p(c_k)$ comme la proportion d'éléments du train set S qui sont de la classe c_k , i.e.

$$p(c_k) = \frac{|S_k|}{N} \text{ , pour tout } k = 1, \dots, K.$$

où S_k est le sous-dataset de S formé des éléments de classe c_k .

ESTIMATION DES PRIORS

- ▶ **Estimation des “class priors”**: l'estimation des $p(Y = c_k) = p(c_k)$ pour $k = 1, \dots, K$ à partir des data est simple.
- ▶ Soit on suppose que toutes les K classes $c_1, \dots, c_K$ sont équiprobables, auquel cas on a:

$$p(c_k) = \frac{1}{K} \text{ , pour tout } k = 1, \dots, K.$$

- ▶ Ou alors on estime $p(c_k)$ comme la proportion d'éléments du train set S qui sont de la classe c_k , i.e.

$$p(c_k) = \frac{|S_k|}{N} \text{ , pour tout } k = 1, \dots, K.$$

où S_k est le sous-dataset de S formé des éléments de classe c_k .

ESTIMATION DES PRIORS

- ▶ **Estimation des “class priors”**: l'estimation des $p(Y = c_k) = p(c_k)$ pour $k = 1, \dots, K$ à partir des data est simple.
- ▶ Soit on suppose que toutes les K classes $c_1, \dots, c_K$ sont équiprobables, auquel cas on a:


$$p(c_k) = \frac{1}{K} \text{ , pour tout } k = 1, \dots, K.$$

- ▶ Ou alors on estime $p(c_k)$ comme la proportion d'éléments du train set S qui sont de la classe c_k , i.e.

$$p(c_k) = \frac{|S_k|}{N} \text{ , pour tout } k = 1, \dots, K.$$

où S_k est le sous-dataset de S formé des éléments de classe c_k .

ESTIMATION DES PRIORS



GAUSSIAN NAIVE BAYES CLASSIFIER

- ▶ **Estimation des “feature distributions”**: l'estimation des $p(X_j = x_j \mid Y = c_k) = p(x_j \mid c_k)$ pour $j = 1, \dots, p$ et $k = 1, \dots, K$ à partir des data diffère selon la nature des data.
- ▶ Si les features X_i sont *continues*, on suppose généralement que chaque $p(X_j \mid Y = c_k)$ suit une *loi normale*, i.e.

$$p(X_j = x_j \mid Y = c_k) \sim \mathcal{N}(\mu_{jk}, \sigma_{jk}^2)$$

- ▶ On obtient alors un **Gaussian naive Bayes classifier**.

GAUSSIAN NAIVE BAYES CLASSIFIER

- ▶ **Estimation des “feature distributions”**: l'estimation des $p(X_j = x_j \mid Y = c_k) = p(x_j \mid c_k)$ pour $j = 1, \dots, p$ et $k = 1, \dots, K$ à partir des data diffère selon la nature des data.
- ▶ Si les features X_i sont *continues*, on suppose généralement que chaque $p(X_j \mid Y = c_k)$ suit une *loi normale*, i.e.

$$p(X_j = x_j \mid Y = c_k) \sim \mathcal{N}(\mu_{jk}, \sigma_{jk}^2)$$

- ▶ On obtient alors un **Gaussian naive Bayes classifier**.

GAUSSIAN NAIVE BAYES CLASSIFIER

- ▶ **Estimation des “feature distributions”**: l'estimation des $p(X_j = x_j \mid Y = c_k) = p(x_j \mid c_k)$ pour $j = 1, \dots, p$ et $k = 1, \dots, K$ à partir des data diffère selon la nature des data.
- ▶ Si les features X_i sont *continues*, on suppose généralement que chaque $p(X_j \mid Y = c_k)$ suit une *loi normale*, i.e.

$$p(X_j = x_j \mid Y = c_k) \sim \mathcal{N}(\mu_{jk}, \sigma_{jk}^2)$$

- ▶ On obtient alors un **Gaussian naive Bayes classifier**.

GAUSSIAN NAIVE BAYES CLASSIFIER

- Pour tout $j = 1, \dots, p$ et pour tout $k = 1, \dots, K$, on estime la moyenne μ_{jk} et la variance σ_{jk}^2 par

$$\mu_{jk} = \frac{1}{|S_k|} \sum_{(\mathbf{x}, y) \in S_k} x_j \quad \text{et} \quad \sigma_{jk}^2 = \frac{1}{(|S_k| - 1)} \sum_{(\mathbf{x}, y) \in S_k} (x_j - \mu_{jk})^2$$

où S_k est le sous-dataset de S formé des éléments qui sont de classe c_k .

- On a donc $2PK$ paramètres (c'est peu !).

GAUSSIAN NAIVE BAYES CLASSIFIER


- Pour tout $j = 1, \dots, p$ et pour tout $k = 1, \dots, K$, on estime la moyenne μ_{jk} et la variance σ_{jk}^2 par

$$\mu_{jk} = \frac{1}{|S_k|} \sum_{(\mathbf{x}, y) \in S_k} x_j \quad \text{et} \quad \sigma_{jk}^2 = \frac{1}{(|S_k| - 1)} \sum_{(\mathbf{x}, y) \in S_k} (x_j - \mu_{jk})^2$$


où S_k est le sous-dataset de S formé des éléments qui sont de classe c_k .

- On a donc $2PK$ paramètres (c'est peu !).


GAUSSIAN NAIVE BAYES CLASSIFIER




GAUSSIAN NAIVE BAYES CLASSIFIER




GAUSSIAN NAIVE BAYES CLASSIFIER



GAUSSIAN NAIVE BAYES CLASSIFIER



GAUSSIAN NAIVE BAYES CLASSIFIER



GAUSSIAN NAIVE BAYES CLASSIFIER

- Ensuite, puisque $p(X_j = \mathbf{x}_j \mid c_k) \sim \mathcal{N}(\mu_{jk}, \sigma_{jk}^2)$, on a

$$p(\mathbf{x}_j \mid c_k) = \frac{1}{\sqrt{2\pi\sigma_{jk}^2}} e^{-\frac{(\mathbf{x}_j - \mu_{jk})^2}{2\sigma_{jk}^2}}$$

- Ainsi, pour tout point $\mathbf{x} = (x_1, \dots, x_P)$ et toute classe c_k , nous avons tout ce qu'il faut pour calculer les formules du naive Bayes classifier:

$$p(c_k \mid \mathbf{x}) \propto p(c_k) \prod_{j=1}^P p(x_j \mid c_k)$$

$$\hat{c} = \arg \max_{c_k \in C} p(c_k) \prod_{j=1}^P p(x_j \mid c_k)$$

GAUSSIAN NAIVE BAYES CLASSIFIER

- Ensuite, puisque $p(X_j = \mathbf{x}_j \mid c_k) \sim \mathcal{N}(\mu_{jk}, \sigma_{jk}^2)$, on a


$$p(\mathbf{x}_j \mid c_k) = \frac{1}{\sqrt{2\pi\sigma_{jk}^2}} e^{-\frac{(\mathbf{x}_j - \mu_{jk})^2}{2\sigma_{jk}^2}}$$

- Ainsi, pour tout point $\mathbf{x} = (x_1, \dots, x_P)$ et toute classe c_k , nous avons tout ce qu'il faut pour calculer les formules du naive Bayes classifier:

$$p(c_k \mid \mathbf{x}) \propto p(c_k) \prod_{j=1}^P p(x_j \mid c_k)$$

$$\hat{c} = \arg \max_{c_k \in C} p(c_k) \prod_{j=1}^P p(x_j \mid c_k)$$

GAUSSIAN NAIVE BAYES CLASSIFIER



MULTINOMIAL NAIVE BAYES CLASSIFIER

- ▶ Si les features X_i sont *discrètes*, on suppose généralement que le vecteur de features $p(\mathbf{X} \mid Y = c_k)$ (et non chaque feature individuelle) suit une *loi multinomiale*, i.e.

$$p(\mathbf{X} = \mathbf{x} \mid Y = c_k) \sim \text{Multinomial}(\pi_{1k}, \dots, \pi_{Pk})$$

où π_{jk} représente la probabilité que le j -ième évènement apparaisse dans la classe c_k .

- ▶ On obtient alors un multinomial naive Bayes classifier.

MULTINOMIAL NAIVE BAYES CLASSIFIER

- ▶ Si les features X_i sont *discrètes*, on suppose généralement que le vecteur de features $p(\mathbf{X} \mid Y = c_k)$ (et non chaque feature individuelle) suit une *loi multinomiale*, i.e.

$$p(\mathbf{X} = \mathbf{x} \mid Y = c_k) \sim \text{Multinomial}(\pi_{1k}, \dots, \pi_{Pk})$$

où π_{jk} représente la probabilité que le j -ième évènement apparaisse dans la classe c_k .

- ▶ On obtient alors un **multinomial naive Bayes classifier**.

MULTINOMIAL NAIVE BAYES CLASSIFIER

- Pour tout $j = 1, \dots, p$ et pour tout $k = 1, \dots, K$, on estime la probabilité π_{jk} par

$$\pi_{jk} = \frac{\sum_{\mathbf{x} \in S_k} x_j}{\sum_{j'=1}^P \sum_{\mathbf{x} \in S_k} x_{j'}}$$

où S_k est le sous-dataset de S formé des éléments qui sont de classe c_k .

- On a donc PK paramètres (c'est peu !).

MULTINOMIAL NAIVE BAYES CLASSIFIER

- Pour tout $j = 1, \dots, p$ et pour tout $k = 1, \dots, K$, on estime la probabilité π_{jk} par

$$\pi_{jk} = \frac{\sum_{\mathbf{x} \in S_k} x_j}{\sum_{j'=1}^P \sum_{\mathbf{x} \in S_k} x_{j'}}$$

où S_k est le sous-dataset de S formé des éléments qui sont de classe c_k .

- On a donc PK paramètres (c'est peu !).

MULTINOMIAL NAIVE BAYES CLASSIFIER

- Ensuite, puisque $p(\mathbf{X} = \mathbf{x} \mid c_k) \sim \text{Multinomial}(\pi_{1k}, \dots, \pi_{Pk})$, on a

$$p(\mathbf{x} \mid c_k) = \left(\frac{\sum_{j=1}^P \mathbf{x}_j!}{\mathbf{x}_1! \dots \mathbf{x}_P!} \right) \pi_{1k}^{\mathbf{x}_1} \dots \pi_{Pk}^{\mathbf{x}_P}$$

- Ainsi, pour tout point $\mathbf{x} = (x_1, \dots, x_P)$ et toute classe c_k , nous avons tout ce qu'il faut pour calculer les formules du naive Bayes classifier:

$$p(c_k \mid \mathbf{x}) \propto p(c_k) \prod_{j=1}^P p(x_j \mid c_k)$$

$$\hat{c} = \arg \max_{c_k \in C} p(c_k) \prod_{j=1}^P p(x_j \mid c_k)$$

MULTINOMIAL NAIVE BAYES CLASSIFIER

- Ensuite, puisque $p(\mathbf{X} = \mathbf{x} \mid c_k) \sim \text{Multinomial}(\pi_{1k}, \dots, \pi_{Pk})$, on a

$$p(\mathbf{x} \mid c_k) = \left(\frac{\sum_{j=1}^P \mathbf{x}_j!}{\mathbf{x}_1! \dots \mathbf{x}_P!} \right) \pi_{1k}^{\mathbf{x}_1} \dots \pi_{Pk}^{\mathbf{x}_P}$$

- Ainsi, pour tout point $\mathbf{x} = (x_1, \dots, x_P)$ et toute classe c_k , nous avons tout ce qu'il faut pour calculer les formules du naive Bayes classifier:

$$p(c_k \mid \mathbf{x}) \propto p(c_k) \prod_{j=1}^P p(x_j \mid c_k)$$

$$\hat{c} = \arg \max_{c_k \in C} p(c_k) \prod_{j=1}^P p(x_j \mid c_k)$$

BIBLIOGRAPHIE



[3Blue1Brown.](#)

Bayes theorem, the geometry of changing beliefs.



[James, G., Witten, D., Hastie, T., and Tibshirani, R. \(2013\).](#)

An Introduction to Statistical Learning: with Applications in R, volume 103 of *Springer Texts in Statistics*.

Springer, New York.



[Wikipedia contributors \(2023\).](#)

Naive bayes classifier — Wikipedia, the free encyclopedia.